

Jean Diniz Ferreira Vasconcelos

Comparação de Investimentos Utilizando Modelos de Machine Learning para Previsão de Retornos e Análise de Risco

Fortaleza

2024

Jean Diniz Ferreira Vasconcelos

Comparação de Investimentos Utilizando Modelos de Machine Learning para Previsão de Retornos e Análise de Risco

Universidade de Fortaleza
MBA em Ciência de Dados

Orientador: Marcus Miranda

Fortaleza
2024

Agradecimentos

Primeiramente, agradeço a Deus, pela força, sabedoria e resiliência para enfrentar os desafios que surgiram ao longo deste MBA.

Aos meus familiares, que foram minha base e meu maior suporte, ofereço minha eterna gratidão. Obrigado por acreditarem em mim, mesmo nos momentos em que eu duvidava de minha própria capacidade.

Aos professores e coordenadores do curso, agradeço profundamente pelos conhecimentos compartilhados, pela paciência em esclarecer dúvidas e pela inspiração em cada aula. Suas contribuições foram fundamentais para meu crescimento e para a realização deste trabalho.

Aos colegas de turma, agradeço pelos momentos de aprendizado mútuo, pelas trocas de ideias e pelo companheirismo ao longo dessa jornada. Cada discussão, desafio em grupo e risada tornou essa experiência ainda mais enriquecedora.

"Tudo vale a pena quando a alma não é pequena.."

— Fernando Pessoa

Resumo

Este trabalho apresenta uma análise comparativa de diferentes estratégias de portfólio, utilizando modelos estatísticos e de aprendizado de máquina para avaliação e previsão de desempenho. Foram analisados dois portfólios principais, um comum e outro otimizado, em relação aos benchmarks IBOV e CDI. Através de métricas como VaR, alfa, beta e R^2 , e modelos como ARIMA e LSTM, investigaram-se as tendências, riscos e retornos de cada portfólio. O portfólio otimizado mostrou-se mais lucrativo no longo prazo, mas também mais volátil, enquanto o portfólio comum apresentou maior estabilidade e consistência no curto prazo. Os resultados reforçam a importância de alinhar a escolha da estratégia ao perfil de risco do investidor, destacando que ambas as abordagens superaram os benchmarks analisados.

Palavras-chave: finanças; machine learning; bolsa de valores.

Abstract

This study conducts a comparative analysis of different portfolio strategies using statistical and machine learning models to assess and forecast performance. Two main portfolios, a standard and an optimized one, were evaluated against IBOV and CDI benchmarks. Key metrics such as VaR, alpha, beta, and R², alongside ARIMA and LSTM models, were employed to explore trends, risks, and returns. The optimized portfolio demonstrated higher profitability in the long term but with increased volatility, whereas the standard portfolio exhibited greater short-term stability and consistency. The findings underscore the importance of aligning strategy selection with the investor's risk profile, highlighting that both approaches outperformed the analyzed benchmarks.

Keywords: finances; machine learning; stock market.

1 Introdução

O mercado financeiro brasileiro tem evoluído significativamente, impulsionado pela digitalização e pelo aumento de investidores individuais. Produtos como ações, fundos de investimento e ETFs tornaram-se mais acessíveis, mas a complexidade e a volatilidade do mercado ainda representam desafios, especialmente na escolha das melhores opções de investimento. (Bodie, 2020)

A previsão de retornos e a análise de riscos são centrais na tomada de decisão financeira. Métodos tradicionais, como a teoria de portfólios e modelos de séries temporais, oferecem fundamentos importantes, mas têm limitações diante da crescente complexidade dos mercados e do volume de dados disponíveis. (Lopez de Prado, 2018)

Nesse contexto, o aprendizado de máquina emerge como uma ferramenta poderosa, capaz de processar grandes volumes de dados, identificar padrões complexos e realizar previsões mais precisas. Modelos como árvores de decisão e redes neurais permitem incorporar fatores externos, como indicadores econômicos e notícias, ampliando as possibilidades de análise. (Lopez de Prado, 2018)

Este trabalho propõe explorar o uso de aprendizado de máquina para comparar ações, fundos de investimento e ETFs, focando em retornos e riscos ajustados. Além de sua relevância prática, o estudo busca contribuir para a literatura acadêmica no contexto brasileiro, onde a aplicação dessas técnicas ainda é limitada. (Lopez de Prado, 2018)

Ao unir ciência de dados e finanças, espera-se oferecer recomendações práticas e criar um framework replicável para análises futuras, destacando o impacto transformador da tecnologia na tomada de decisões financeiras.

2 Objetivos

2.1 Objetivo Geral

Este trabalho tem como objetivo principal comparar diferentes opções de investimento disponíveis no mercado financeiro brasileiro, como ações, fundos de investimento e ETFs, com base em previsões de retorno e análises de risco. Para isso, serão aplicados modelos de Machine Learning, explorando técnicas avançadas de predição e análise quantitativa. O propósito é identificar as opções de investimento que apresentam o melhor equilíbrio entre retorno potencial e risco associado, fornecendo subsídios fundamentados para decisões mais eficazes no contexto financeiro.

2.2 Objetivos Específicos

2.2.1 Coletar e preparar dados históricos

- Reunir dados históricos de ações da Bolsa de Valores do Brasil (B3), fundos de investimento registrados na ANBIMA e ETFs disponíveis no mercado brasileiro.
- Tratar os dados coletados, o que inclui a remoção de valores nulos, correção de inconsistências, e transformação de variáveis, preparando-os para análises futuras.

2.2.2 Realizar análises exploratórias

- Analisar os dados coletados para identificar características importantes, como médias históricas de retorno, volatilidade e correlações entre ativos.
- Visualizar a distribuição dos retornos financeiros e padrões temporais, detectando tendências e sazonalidades.
- Investigar anomalias ou eventos extremos nos dados, como quedas acentuadas nos mercados, e avaliar como podem influenciar os resultados das análises.

2.2.3 Desenvolver modelos preditivos

- Implementar algoritmos de Machine Learning, como regressões lineares, e redes neurais artificiais, para prever os retornos financeiros de cada opção de investimento.
- Utilizar técnicas de validação cruzada para treinar e testar os modelos, garantindo que os resultados obtidos sejam generalizáveis e robustos.

- Aplicar métricas de avaliação, como Raiz do Erro Quadrático Médio (RMSE), Erro Médio Absoluto (MAE), e R^2 , para medir a qualidade das previsões geradas por cada modelo.
- Comparar o desempenho entre diferentes algoritmos, identificando aqueles mais adequados ao problema de previsão de retornos financeiros.
- Analisar os modelos não apenas quanto à precisão preditiva, mas também quanto à interpretabilidade, especialmente em contextos onde decisões precisam ser justificadas.

2.2.4 Comparar investimentos com base em retorno e risco

- Utilizar as previsões geradas pelos modelos para calcular métricas de risco e retorno, como volatilidade e índice de Sharpe, considerando as características individuais de cada ativo.
- Incorporar cenários hipotéticos de mercado para avaliar a robustez das recomendações, como variações de alta ou baixa significativa nos índices econômicos.

3 Metodologia

3.1 Definir o portfólio e o Período de Tempo

3.1.1 Definição dos Tickers

Os tickers escolhidos para compor o portfólio são símbolos de ações listadas na B3, representando empresas de setores distintos. Essa diversificação setorial é importante para reduzir o risco não sistêmico, ou seja, aquele associado a fatores específicos de uma empresa ou setor. Abaixo, uma breve descrição das empresas selecionadas:

PETR4.SA (Petrobras - PN): Representa a Petrobrás, uma das maiores empresas de energia do Brasil, com foco em exploração, produção, refino e distribuição de petróleo e gás. A exposição a commodities torna esse ativo sensível a flutuações de preços internacionais e câmbio.

SBSP3.SA (Sabesp): Atua no setor de saneamento básico, oferecendo serviços de abastecimento de água e tratamento de esgoto. Este é um ativo defensivo, geralmente menos afetado por ciclos econômicos.

RENT3.SA (Localiza): Empresa líder no mercado de aluguel de veículos e gestão de frotas no Brasil. É uma escolha do setor de consumo, que pode capturar oportunidades de crescimento econômico.

ITUB4.SA (Itaú Unibanco - PN): Um dos maiores bancos do Brasil, representando o setor financeiro. Os bancos geralmente oferecem uma combinação de estabilidade e crescimento em economias emergentes.

VALE3.SA (Vale): Representa a Vale, uma das maiores mineradoras do mundo, com foco na produção de minério de ferro e níquel. Assim como a Petrobras, está altamente exposta a mercados internacionais e ao dólar.

3.1.2 Benchmark, pesos e horizonte temporal

Para comparação de desempenho, foi escolhido o índice IBOVESPA (BVSP), que é o principal indicador do mercado de ações brasileiro, abrangendo uma cesta ponderada de ações das empresas mais negociadas na bolsa.

Os pesos foram igualmente distribuídos entre os ativos (20% para cada). Essa estratégia de alocação inicial simplifica o portfólio e permite observar como cada ativo contribui para o desempenho total.

O período de análise foi definido como três anos. Isso permite capturar diferentes

ciclos de mercado e observar o impacto de eventos econômicos e financeiros relevantes.

3.2 Coleta dos Dados

3.2.1 Histórico de Ativos

Para analisar o desempenho dos ativos escolhidos, foi realizada a coleta de dados históricos de preços ajustados de fechamento utilizando o pacote yfinance. Esse pacote permite acessar facilmente informações financeiras de ativos listados em bolsas de valores globais.

Ao final, o DataFrame resultante contém uma estrutura onde cada coluna representa o histórico de preços de um ativo, enquanto as linhas correspondem às datas do período selecionado. Isso fornece uma base robusta para análises exploratórias e modelagem preditiva.

Date	PETR4.SA	SBSP3.SA	RENT3.SA	ITUB4.SA	VALE3.SA
2021-12-27	11.321489	37.483788	50.164104	18.436710	62.010883
2021-12-28	11.333305	37.474430	48.797237	18.368299	60.518543
2021-12-29	11.238796	37.296600	47.475933	18.214373	60.675625
2021-12-30	11.203356	37.605461	48.296047	17.915085	61.233288
2022-01-03	11.455381	37.390194	46.373322	18.409460	61.264713
...
2024-12-17	36.919903	90.589996	30.775309	31.879999	56.110001
2024-12-18	35.965580	87.900002	29.930000	30.969999	54.810001
2024-12-19	35.820984	87.190002	32.549999	31.139999	53.770000
2024-12-20	35.522152	86.620003	33.680000	31.500000	54.619999
2024-12-23	35.531796	88.400002	32.880001	30.889999	54.849998

Figura 1 – Dataframe do portfólio.

3.2.2 CDI

O CDI é uma taxa de juros utilizada como referência no mercado financeiro brasileiro, refletindo o custo do empréstimo interbancário de curtíssimo prazo entre os bancos. Ele é considerado a taxa livre de risco, pois reflete a rentabilidade de investimentos de baixo risco, como os Certificados de Depósito Bancário (CDBs). Em análises de portfólio, o CDI é utilizado como benchmark para avaliar o desempenho dos ativos. Quando um investimento não supera a taxa CDI, ele é considerado de baixo retorno em comparação com investimentos sem risco.

A taxa CDI é utilizada para calcular a taxa livre de risco no mercado financeiro. Esta taxa serve como parâmetro para avaliar o retorno ajustado pelo risco de um portfólio de investimentos. A taxa livre de risco é essencial para o cálculo de métricas como o Sharpe Ratio, que mede o retorno de um investimento em relação ao risco assumido. O Sharpe Ratio permite determinar se o retorno de um portfólio justifica o risco adicional em relação à rentabilidade do CDI.

3.2.3 Índice IBOV

O Índice Bovespa (IBOV) é o principal indicador do mercado de ações brasileiro. Ele reflete o desempenho das ações mais negociadas na B3 (Bolsa de Valores de São Paulo) e serve como benchmark para o mercado de ações. O IBOV é ponderado pelo valor de mercado das empresas que o compõem e é utilizado para comparar o desempenho de um portfólio com o mercado acionário como um todo. Superar o desempenho do IBOV é considerado um indicador de sucesso na gestão do portfólio de ações.

3.3 Preparação dos Dados

Nesta seção, os dados financeiros coletados são preparados para análise por meio do cálculo de retornos. O retorno de um ativo é uma medida da mudança no valor de um ativo em um determinado período e é fundamental para avaliar a performance do portfólio de investimentos. Neste caso, são calculados os retornos logarítmicos (ou log-normais), que são amplamente utilizados em finanças, especialmente para modelar o comportamento dos preços de ativos e seus retornos.

3.3.1 Calculo dos Retornos em Log-Normal

Logarithmic Returns (ou retornos logarítmicos) são calculados para cada ativo do portfólio, utilizando a fórmula: O retorno logarítmico r_t no tempo t é dado pela fórmula:

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right)$$

onde:

- r_t é o retorno logarítmico no tempo t ,
- P_t é o preço ajustado de fechamento no tempo t ,
- P_{t-1} é o preço ajustado de fechamento no tempo $t - 1$,
- \ln é o logaritmo natural.

O cálculo dos retornos logarítmicos é feito utilizando a função `np.log()`, que aplica o logaritmo natural à razão entre o preço ajustado atual e o anterior, o que é feito para cada ativo no portfólio. Esse tipo de retorno é preferido em muitos modelos financeiros porque é aditivo e mais fácil de ser interpretado em termos de distribuições normais.

3.3.2 Cálculo dos Retornos do Índice IBOV Diário

O mesmo procedimento de cálculo de retornos logarítmicos é feito para o Índice Bovespa (IBOV), com o objetivo de acompanhar a performance do mercado como um todo. O cálculo segue a mesma fórmula de retornos logarítmicos, utilizando os preços ajustados diários do índice Bovespa.

3.3.3 Cálculo dos Retornos do CDI

O CDI também é tratado de forma semelhante, já que ele representa a taxa de juros diária do mercado interbancário e é utilizado como benchmark para a rentabilidade de investimentos livres de risco. O cálculo dos retornos logarítmicos do CDI segue a mesma lógica aplicada aos ativos e ao IBOV.

3.3.4 Cálculo dos Retornos Históricos do Portfolio

Agora, os retornos históricos do portfólio são calculados. A ideia é calcular o retorno ponderado de todos os ativos do portfólio, levando em consideração os pesos de cada ativo. Isso é feito multiplicando os retornos logarítmicos de cada ativo pelos seus respectivos pesos e somando o resultado para obter o retorno total do portfólio.

	PETR4.SA	SBSP3.SA	RENT3.SA	ITUB4.SA	VALE3.SA
Date					
2021-12-28	0.001043	-0.000250	-0.027626	-0.003717	-0.024360
2021-12-29	-0.008374	-0.004757	-0.027451	-0.008415	0.002592
2021-12-30	-0.003158	0.008247	0.017127	-0.016568	0.009149
2022-01-03	0.022246	-0.005741	-0.040625	0.027222	0.000513
2022-01-04	0.003774	-0.027921	0.005682	0.027965	-0.011865
...
2024-12-17	0.009444	0.017707	0.015189	0.005347	0.005003
2024-12-18	-0.026188	-0.030144	-0.027851	-0.028960	-0.023441
2024-12-19	-0.004029	-0.008110	0.083916	0.005474	-0.019157
2024-12-20	-0.008377	-0.006559	0.034127	0.011494	0.015684
2024-12-23	0.000271	0.020341	-0.024040	-0.019555	0.004202

749 rows × 5 columns

Figura 2 – Dataframe do portfólio com os retornos logaritmizados.

4 Análise Exploratória

A Análise Exploratória dos Dados (AED) tem como objetivo entender o comportamento e as características dos ativos dentro de um portfólio de investimentos, analisando tanto os preços históricos quanto os retornos. A seguir, exploramos três aspectos principais dessa análise: Preço, Retornos, e Análise Temporal dos Ativos.

4.1 Análise dos Ativos

4.1.1 Preço

A primeira etapa na análise dos ativos é a visualização dos preços de fechamento ajustados de cada ativo presente no portfólio. Este gráfico permite observar como os preços evoluíram ao longo do tempo. A seguir, também é apresentado o IBOV, principal índice da bolsa brasileira, para comparar o desempenho dos ativos em relação ao mercado.

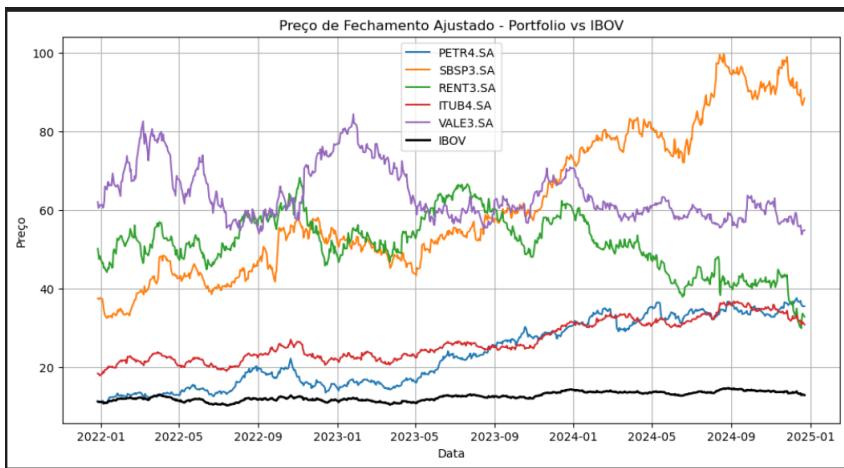


Figura 3 – Análise do Preço dos ativos

4.1.2 Retornos

A análise de retornos é fundamental para entender a performance dos ativos em termos de ganho ou perda ao longo do tempo. A abordagem aqui adotada é o retorno acumulado de cada ativo, comparando-os com benchmarks como o CDI (Certificado de Depósito Interbancário) e o IBOV.

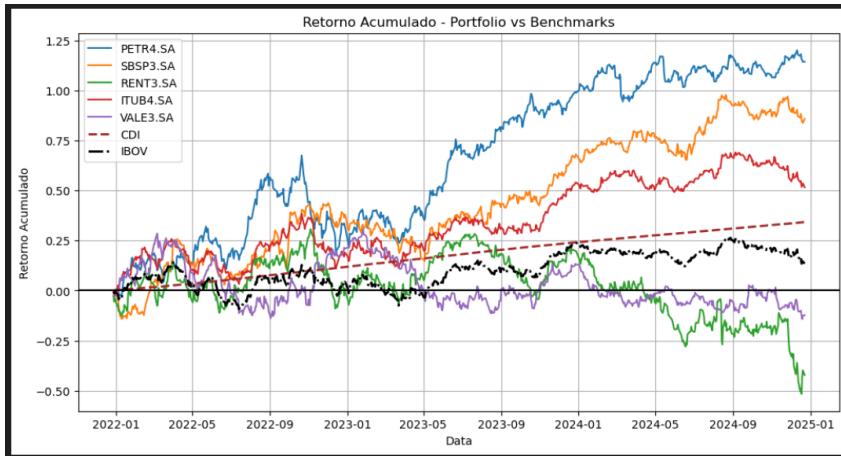


Figura 4 – Análise do Retorno dos Ativos

4.1.3 Análise Temporal

A análise temporal é mais detalhada, buscando entender a decomposição dos preços e identificar padrões sazonais ou de tendência. A decomposição envolve a separação dos dados em quatro componentes: observado, tendência, sazonalidade, e resíduos. Além disso, são realizados testes estatísticos como o Shapiro-Wilk para verificar a normalidade dos resíduos e o Teste de Dickey-Fuller Aumentado para avaliar a estacionariedade dos dados.

A decomposição é realizada utilizando a função `seasonal_decompose`, e a análise de autocorrelação é feita com gráficos de ACF (Autocorrelation Function) e PACF (Partial Autocorrelation Function).

Os resultados da análise temporal dos ativos do portfólio indicam que as séries de preços ajustados não seguem uma distribuição normal, conforme apontado pelo Teste de Shapiro-Wilk, que apresentou p-valores menores que 0.05 para todos os ativos analisados. Isso sugere que os dados possuem características que diferem de uma distribuição normal, como assimetria ou caudas mais pesadas.

exemplo do ticker Petrobrás (PETR4):

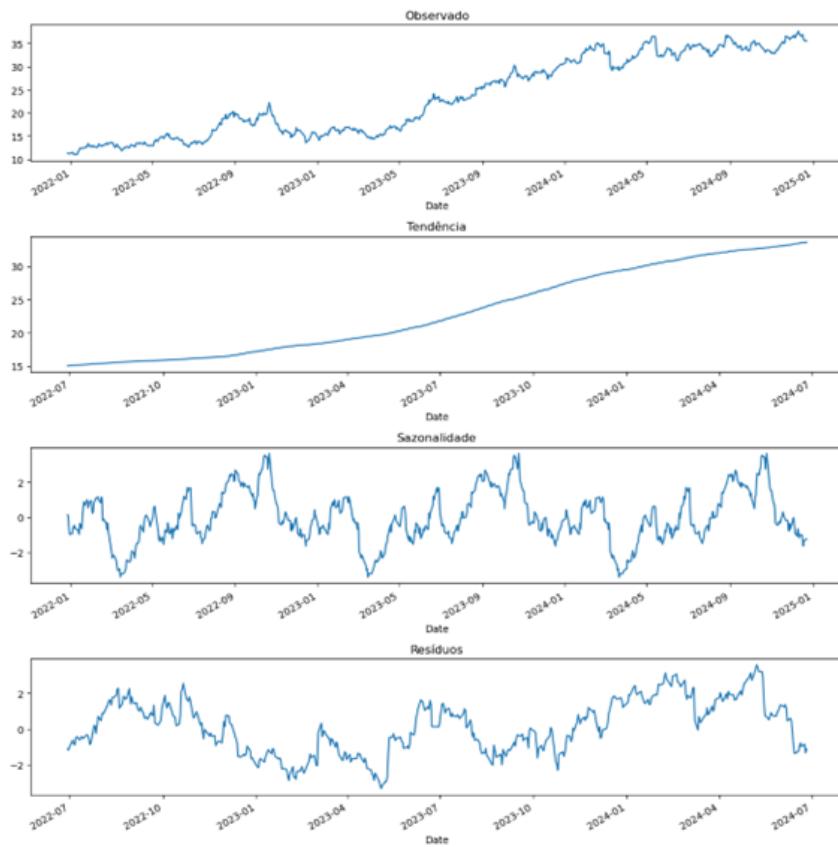


Figura 5 – Exemplo de uma decomposição de um dos ativos do portfólio

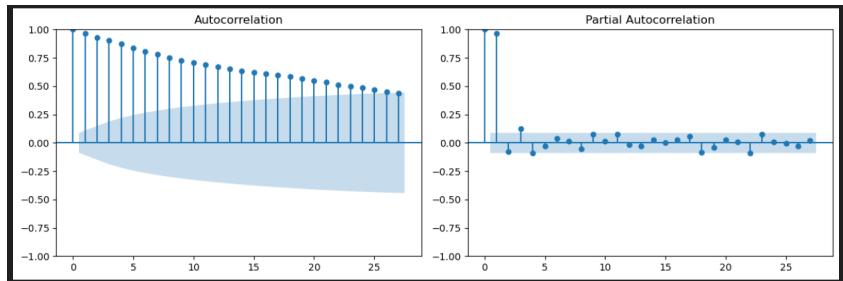


Figura 6 – Autocorrelação e Autocorrelação Parcial dos resíduos

```

Teste de Shapiro-Wilk para PETR4.SA: Estatística=0.985, p-valor=0.000
Provavelmente não normal
Teste de Dickey-Fuller Aumentado para PETR4.SA:
ADF Statistic: -0.749834
p-value: 0.833416
Critical Values:
 1%: -3.439
 5%: -2.865
 10%: -2.569
Série provavelmente não estacionária

```

Figura 7 – Teste de normalidade dos resíduos (Shapiro-Wilk) / Teste de estacionariedade (Dickey-Fuller Aumentado)

Além disso, o Teste de Dickey-Fuller Aumentado (ADF) revelou que as séries são provavelmente não estacionárias, com p-valores superiores a 0.05 em todos os casos. Isso implica que as séries possuem média e variância não constantes ao longo do tempo, podendo apresentar tendências ou sazonalidade que afetam sua previsibilidade. Algo que se repete em boa parte dos tickers analisados aqui.

A decomposição das séries temporais permitiu identificar os componentes individuais de tendência, sazonalidade e resíduos, oferecendo uma visão mais detalhada das dinâmicas subjacentes. Essa análise mostrou que, embora padrões sazonais possam existir em alguns ativos, os resíduos exibem comportamento aleatório, indicando a necessidade de ajustes adicionais para modelagem e previsões mais precisas.

Os resultados apontaram que as séries analisadas geralmente não seguem uma distribuição normal e não são estacionárias, o que é esperado em dados financeiros. Essas características sugerem a necessidade de transformações nos dados antes de aplicar modelos preditivos. A análise de padrões, tendências e sazonalidades é crucial para a modelagem e previsão desses ativos, ajudando a tomar decisões informadas no contexto financeiro.

Analisar ativo a ativo de forma separada é essencial para entender as particularidades e comportamentos individuais de cada ativo antes de compô-los em um portfólio. Essa análise permite identificar características como tendências, sazonalidades, volatilidade e risco, fatores que podem impactar diretamente o desempenho do portfólio. No processo de construção de um portfólio, é fundamental compreender o comportamento de cada ativo para equilibrar o risco e a rentabilidade, otimizando a diversificação e melhorando os retornos ajustados ao risco. Embora a análise detalhada de cada ativo não será abordada de forma aprofundada neste estudo, pois o foco principal está na análise do portfólio como um todo, esse passo inicial de análise de ativos individuais é fundamental para garantir uma alocação eficiente dos recursos.

4.1.4 Cálculo da Matriz de Covariância

A matriz de covariância é uma ferramenta importante para entender como os ativos do portfólio se comportam em conjunto, ou seja, como os retornos de um ativo estão relacionados aos retornos de outros ativos. A covariância é calculada a partir dos retornos logarítmicos anuais dos ativos.

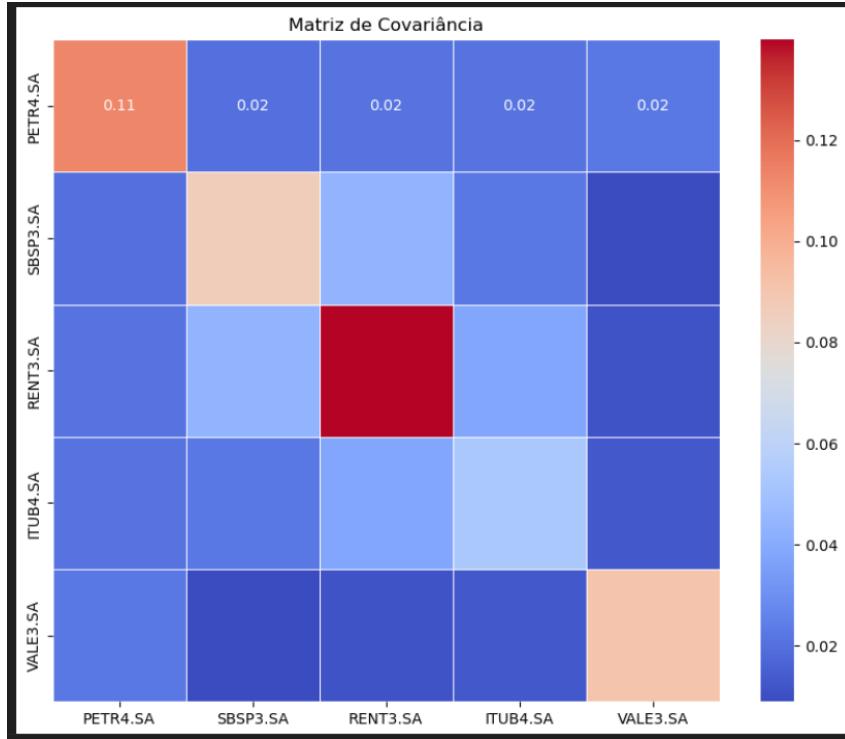


Figura 8 – Visualização de uma análise de covariância

4.2 Análise do Portfólio

4.2.1 X-Day dos Retornos Históricos do Portfolio

O X-Day é utilizado para calcular o VaR (Value at Risk), que estima a perda máxima que o portfólio pode ter dentro de um intervalo de confiança de 95%. Várias janelas de tempo são analisadas (30, 60, 90, 180, 252 dias) para calcular o VaR e determinar a melhor janela de tempo, ou seja, a que oferece o valor mais baixo de risco.

4.2.2 VaR (Value at Risk)

O Value at Risk (VaR) é uma métrica amplamente utilizada no mercado financeiro para quantificar o risco de perdas potenciais em um portfólio. Ele representa a perda máxima esperada, em condições normais de mercado, durante um período específico, com um nível de confiança definido.

Neste estudo, considerando uma janela de 252 dias e um nível de confiança de 95

Resultados do VaR para diferentes janelas de tempo:

Janela de 30 dias: VaR = R\$ 8564.22

Janela de 60 dias: VaR = R\$ 8836.17

Janela de 90 dias: VaR = R\$ 7724.95

Janela de 180 dias: VaR = R\$ 814.75

Janela de 252 dias: VaR = R\$ -596.91

Melhor janela de tempo: 252 dias com VaR = R\$ -596.91

Figura 9 – Valores do Value at Risk para o período analisado.

Um valor negativo no VaR reflete a natureza de perdas no mercado financeiro, sinalizando que o resultado esperado é uma redução no valor do portfólio em cenários adversos. À medida que o período aumenta para 252 dias, o valor de VaR se reduz em magnitude, o que pode sugerir que o portfólio apresenta maior estabilidade no longo prazo.

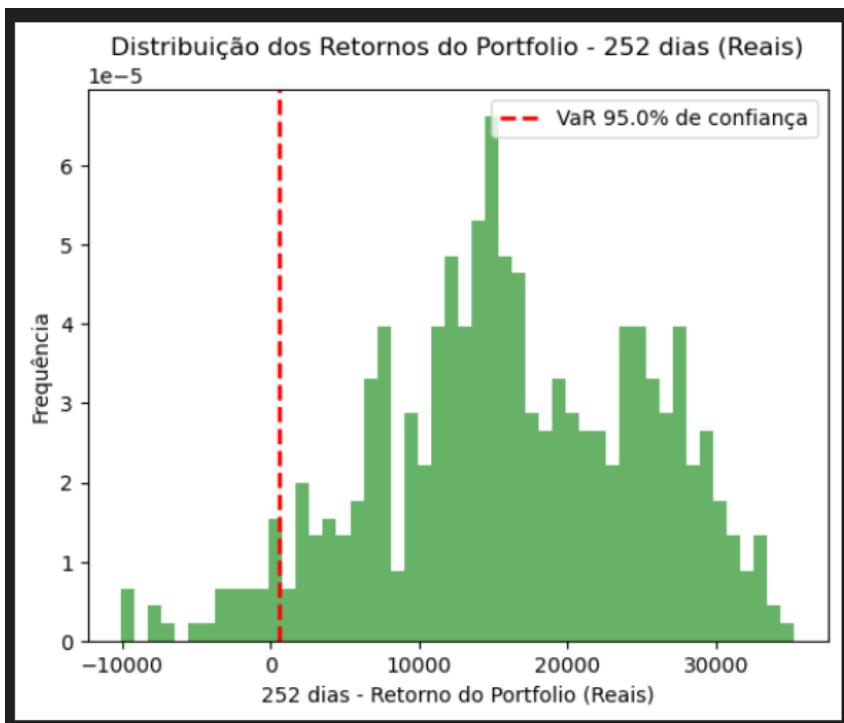


Figura 10 – Distribuição de valores do Value at Risk para o período analisado.

4.2.3 Backtesting

Backtesting avalia o desempenho de modelos financeiros, como o Value at Risk (VaR), utilizando dados históricos para verificar sua eficácia. Comparando perdas previstas e observadas em um período, calcula-se a taxa de violação, que indica a frequência de perdas reais que excedem o VaR.

No teste realizado para 252 dias, a taxa de violação observada foi de 0,9538. Esse valor, próximo de 1, sugere que o modelo subestimou significativamente as perdas, indicando que ele não foi eficaz em capturar a volatilidade ou os riscos reais durante o período analisado.

4.2.4 Stress Test

O Stress Test avalia a resiliência de um portfólio em cenários extremos de mercado, simulando choques como quedas severas nos preços dos ativos ou variações abruptas nas taxas de juros e câmbio.

Com um choque de 50%, o portfólio apresentou um VaR de R\$ -298,46, indicando a perda máxima esperada nesse cenário com 95% de confiança. Esse resultado significa que, sob condições extremas simuladas, a perda do portfólio seria de até R\$ 298,46, sugerindo que o portfólio tem uma capacidade limitada de perdas em situações adversas.

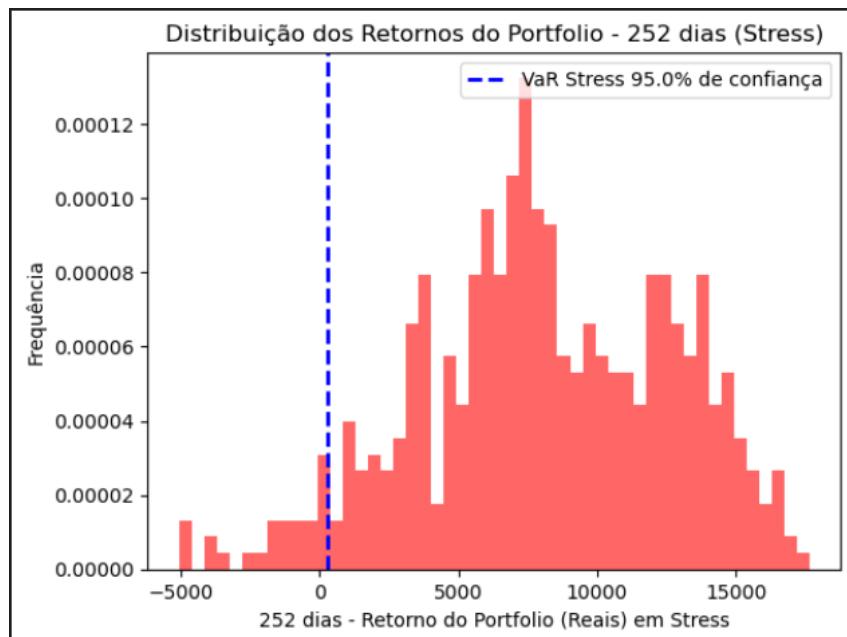


Figura 11 – Análise do Stress para as janelas de análise

4.2.5 Análise dos Retornos do Portfolio Escolhido

Por fim, é feita uma comparação entre o retorno acumulado do portfólio e os benchmarks (CDI e IBOV), para entender como o portfólio se comporta em relação a esses índices. As diferenças de saldo entre o portfólio e os benchmarks também são calculadas para medir a performance relativa.

O retorno acumulado de cada série (portfólio, CDI e IBOV) é calculado e comparado, destacando as diferenças. Essas análises fornecem uma visão detalhada sobre o

comportamento do portfólio, a performance dos ativos e o risco envolvido, permitindo uma gestão mais eficiente e informada do portfólio de investimentos.

Dados Iniciais:

- Saldo do Portfólio: R\$ 139.452,69
- Saldo do CDI: R\$ 134.216,29
- Saldo do IBOV: R\$ 113.485,83

Diferenças de Performance:

- Diferença Portfólio vs. CDI: R\$ 5.236,40, o que representa 5,23% a mais do que o CDI.
- Diferença Portfólio vs. IBOV: R\$ 25.966,86, o que representa 25,96% a mais do que o IBOV.

Crescimento Acumulado:

O portfólio teve um desempenho 39,45% acima do valor inicial, superando tanto o CDI quanto o IBOV de forma significativa ao longo de três anos. Isso indica que, no período de análise, o portfólio obteve um retorno melhor do que ambas as referências.

Retorno Anual Médio:

- Portfólio: 11,80% ao ano
- CDI: 10,20% ao ano
- IBOV: 4,33% ao ano
- Comparação de Métricas:

Métrica	Portfolio	CDI	IBOV
Retorno Médio Anualizado	0.132561	0.114509	0.045373
Desvio Padrão Anualizado	0.192243	0.000788	0.174015
Sharpe Ratio	0.687183	144.670125	0.258126

Figura 12 – Análise do retorno acumulado do portfólio vs. benchmark

Interpretação:

- Retorno Médio Anualizado: Seu portfólio apresentou uma média de 11,80% ao ano, superior ao CDI, que foi de 10,20% ao ano, e ao IBOV, que teve 4,33% ao ano.
- Sharpe Ratio: A relação Sharpe para o seu portfólio é de 0,69, indicando um retorno ajustado ao risco razoável. O CDI, com um valor extremamente alto de 144,67, provavelmente representa uma anomalia ou erro de cálculo na base de dados. O IBOV possui uma Sharpe ratio de 0,26, o que sugere um retorno mais baixo em relação ao risco.

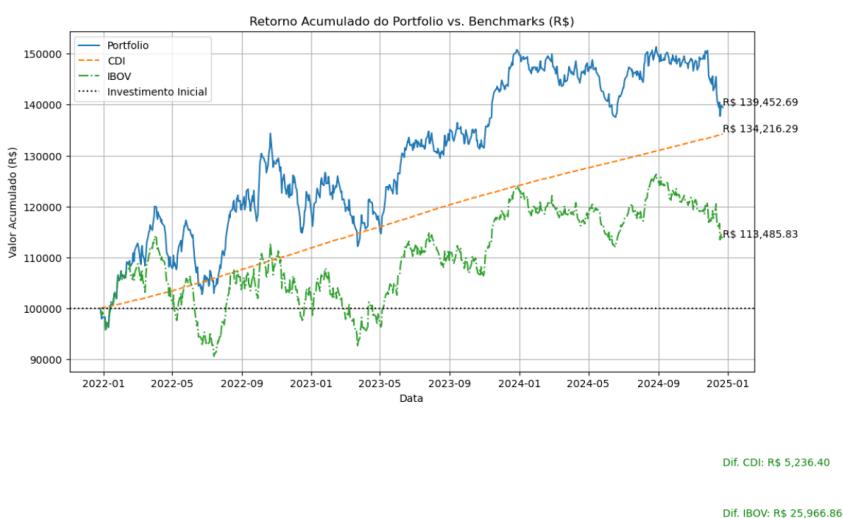


Figura 13 – Análise do retorno acumulado do portfólio vs. benchmark

Concluindo que o portfólio rendeu aproximadamente 115,7% do CDI ao longo de 3 anos, o que significa que, em média, superou o CDI em 15,7% anualmente. Isso reflete que seu portfólio apresentou uma rentabilidade superior ao CDI, e significativamente mais alta que o IBOV, demonstrando um bom desempenho relativo no período.

5 Modelagem e Previsão

5.1 Previsão do Portfólio

5.1.1 Portfólio - CAPM

O CAPM (Capital Asset Pricing Model) é um modelo amplamente utilizado para estimar o retorno esperado de um ativo ou portfólio, levando em consideração o risco sistemático, ou seja, aquele risco que não pode ser diversificado. Esse modelo se baseia em três fatores principais: a taxa livre de risco, o risco do mercado e o retorno esperado do mercado.

Por exemplo, no caso do portfólio em questão, o beta foi calculado como 1.0145, o que significa que o portfólio é ligeiramente mais volátil que o mercado, com uma sensibilidade maior às flutuações do IBOV. O retorno esperado segundo o CAPM foi de 4.60% ao ano, o que é o retorno sugerido para o portfólio, dado seu risco sistemático. O alfa do portfólio foi de 0.0867, ou 8.67%, indicando que o portfólio superou as expectativas do modelo CAPM, sugerindo uma gestão eficaz ou uma boa seleção de ativos. O erro de previsão foi igual ao alfa, o que confirma que o modelo subestimou o retorno do portfólio, sendo exatamente compensado pelo desempenho superior. Por fim, o R-quadrado foi de 84.22%, o que significa que a maior parte dos retornos do portfólio é explicada pelas flutuações do mercado, refletindo uma forte correlação entre o portfólio e o IBOV.

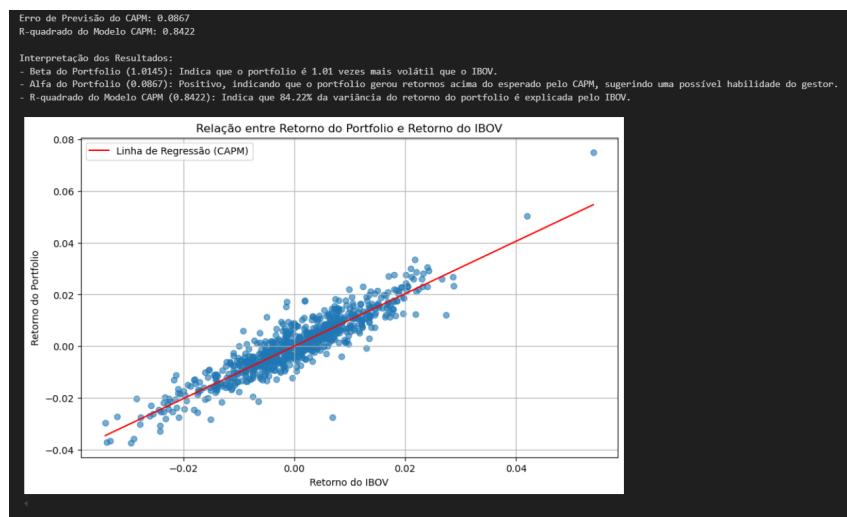


Figura 14 – Relação entre retorno do portfólio e retorno do índice IBOV

Esses resultados são muito positivos, pois indicam que o portfólio não apenas segue de forma consistente o mercado, mas também consegue gerar retornos acima do

esperado, o que é um reflexo de uma boa gestão e/ou estratégias de seleção de ativos. Assim, o modelo CAPM, aliado a essas métricas, fornece uma base sólida para avaliar a performance de um portfólio de investimentos, ajudando os investidores a tomar decisões mais informadas e a ajustar suas estratégias conforme o risco e o retorno esperado.

5.1.2 Portfólio - Regressão Linear

Neste modelo de regressão linear, o objetivo é analisar a relação entre o tempo e o retorno do portfólio, buscando identificar a linha que melhor se ajusta aos dados.

Regressão Linear: Modelo Básico A regressão linear é utilizada para encontrar uma linha que melhor represente a relação entre o tempo (eixo x) e o retorno do portfólio (eixo y), proporcionando uma previsão para os retornos futuros com base no tempo.

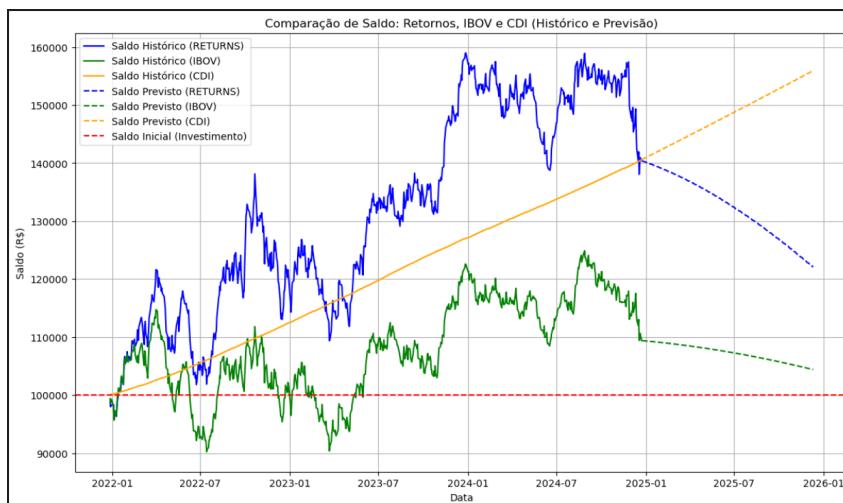


Figura 15 – Regressão Linear do Retorno do portfólio x Retorno do IBOV

Gráfico de Regressão Linear As métricas obtidas para a regressão linear são:

- RETURNS:
 - MSE: 0.000146
 - MAE: 0.009275
 - R²: 0.001538
- IBOV:
 - MSE: 0.000120
 - MAE: 0.008452
 - R²: 0.000215

- CDI:
 - MSE: 0.000000
 - MAE: 0.000038
 - R^2 : 0.142434

O valor de R^2 para os diferentes modelos indica o quanto bem a linha de regressão se ajusta aos dados. Os resultados para RETURNS e IBOV apresentam valores muito baixos de R^2 , 0.001538 e 0.000215, respectivamente, sugerindo que a relação entre o tempo e o retorno, nesses casos, não é bem explicada pelo modelo linear. Em contrapartida, o CDI apresenta um valor de R^2 de 0.142434, sugerindo que o tempo e o retorno do CDI têm uma correlação um pouco mais forte, sendo mais bem representados pela regressão linear.

Esses resultados indicam que, embora a regressão linear forneça uma aproximação inicial, ela não é totalmente eficaz para modelar o comportamento do retorno ao longo do tempo, especialmente no caso de RETURNS e IBOV. O modelo de CDI, por outro lado, mostra um desempenho melhor, com maior explicação da variação dos dados.

5.1.3 Previsão do Portfólio - ARIMA

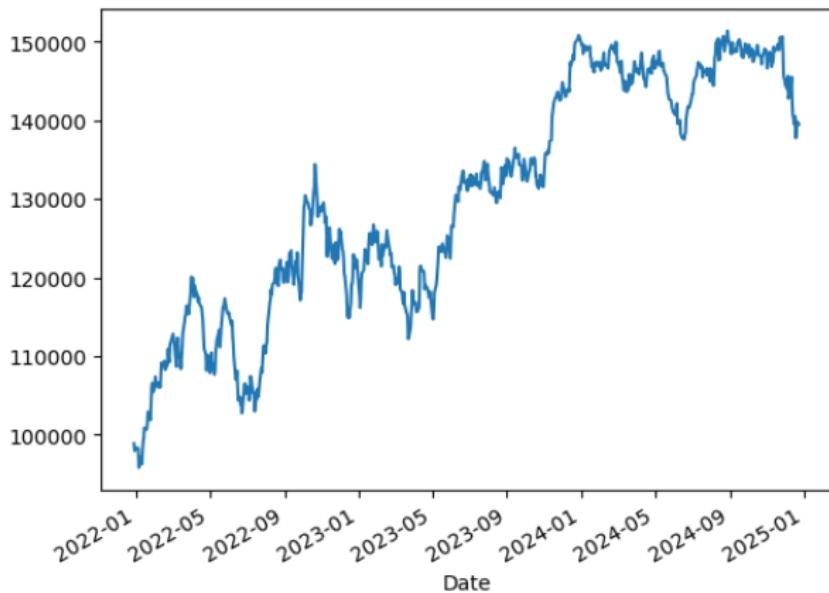


Figura 16 – Retornos de portfólio

O processo de previsão do retorno de um portfólio utilizando o modelo ARIMA envolve diversas etapas importantes para modelar e entender o comportamento dos retornos acumulados ao longo do tempo. O primeiro passo é calcular o retorno acumulado do portfólio, que é obtido somando os retornos diários de forma acumulada e multiplicando

pelo valor inicial do portfolio. Essa abordagem fornece uma visualização do desempenho do portfolio, resultando em uma série temporal que será analisada em detalhes.

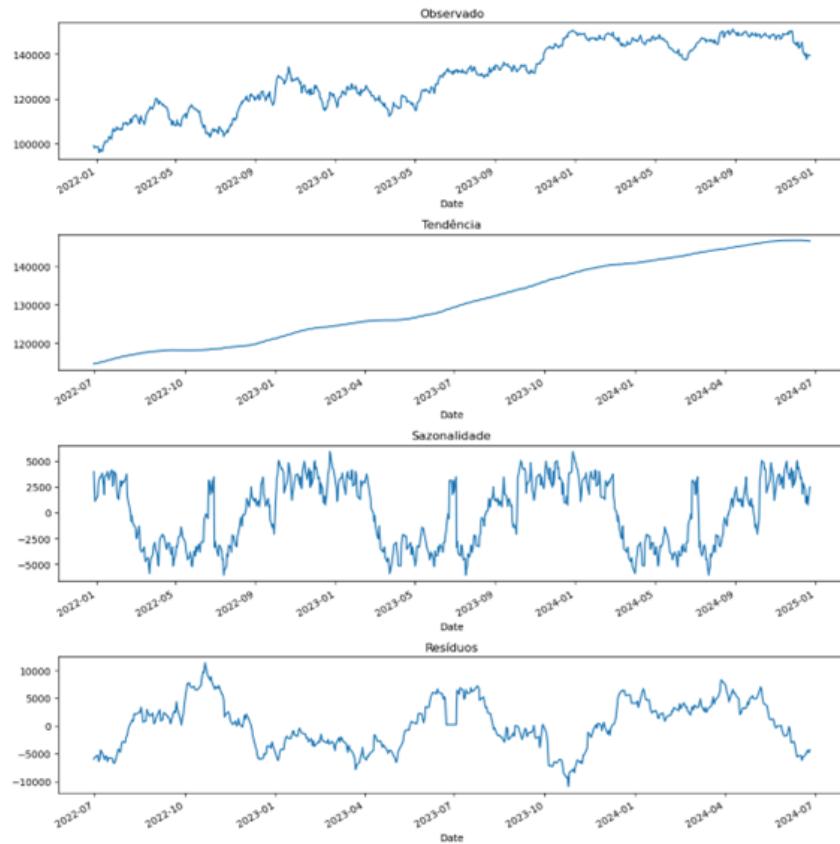


Figura 17 – Decomposição de portfólio

Após calcular o retorno acumulado, a decomposição sazonal da série temporal é realizada utilizando o modelo aditivo. Isso permite separar a série em quatro componentes principais: observada, tendência, sazonalidade e resíduos. A decomposição é fundamental para entender como cada uma dessas partes contribui para o comportamento do retorno. A tendência e a sazonalidade oferecem uma visão sobre os padrões subjacentes, enquanto os resíduos capturam as variações não explicadas por esses componentes.

```

Teste de Shapiro-Wilk para retornos do portfolio: Estatística=0.985, p-valor=0.000
Provavelmente não normal

Teste de Dickey-Fuller Aumentado para retornos do portfolio:
ADF Statistic: -2.233320
p-value: 0.194375
Critical Values:
 1%: -3.439
 5%: -2.865
 10%: -2.569
Série provavelmente não estacionária

```

Figura 18 – Teste de normalidade dos resíduos (Shapiro-Wilk) & Teste de estacionariedade (Dickey-Fuller Aumentado)

Um passo essencial na modelagem de séries temporais é a análise dos resíduos. Realiza-se primeiramente um teste de normalidade, como o teste de Shapiro-Wilk, para verificar se os resíduos seguem uma distribuição normal, uma suposição comum em modelos de séries temporais. No caso dos retornos do portfolio, o teste de Shapiro-Wilk gerou uma estatística de 0.984 e um p-valor de 0.000, o que indica que os resíduos provavelmente não seguem uma distribuição normal. Além disso, é aplicado o teste de Dickey-Fuller Aumentado para avaliar a estacionariedade da série temporal. O teste retornou um valor de ADF de -1.598112 e um p-valor de 0.484542, o que indica que a série provavelmente não é estacionária. Isso significa que é necessário realizar transformações, como a diferenciação, para tornar a série estacionária, um requisito importante para a modelagem ARIMA.

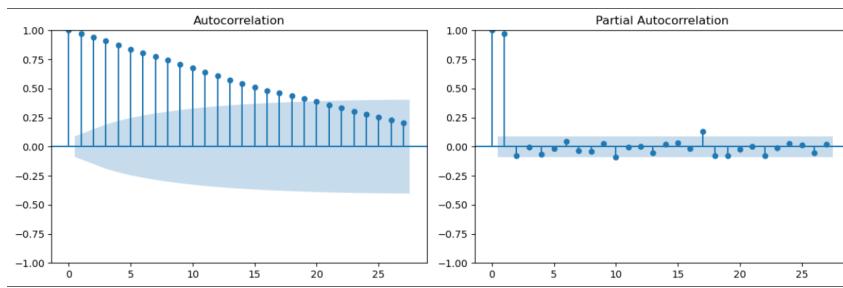


Figura 19 – Autocorrelação e Autocorrelação Parcial dos resíduos

Em seguida, a análise de autocorrelação e autocorrelação parcial é feita para examinar a estrutura de dependência temporal da série, ajudando a identificar os melhores parâmetros para o modelo ARIMA. Essa análise orienta a escolha dos lags apropriados, fundamentais para a configuração correta do modelo.

```

Performing stepwise search to minimize aic
ARIMA(1,0,1)(0,0,0)[0] intercept : AIC=12774.188, Time=0.06 sec
ARIMA(0,0,0)(0,0,0)[0] intercept : AIC=16526.945, Time=0.01 sec
ARIMA(1,0,0)(0,0,0)[0] intercept : AIC=inf, Time=0.03 sec
ARIMA(0,0,1)(0,0,0)[0] intercept : AIC=15573.367, Time=0.20 sec
ARIMA(0,0,0)(0,0,0)[0] : AIC=19776.675, Time=0.01 sec
ARIMA(2,0,1)(0,0,0)[0] intercept : AIC=12773.558, Time=0.43 sec
ARIMA(2,0,0)(0,0,0)[0] intercept : AIC=inf, Time=0.15 sec
ARIMA(3,0,1)(0,0,0)[0] intercept : AIC=12775.155, Time=0.12 sec
ARIMA(2,0,2)(0,0,0)[0] intercept : AIC=12775.886, Time=0.23 sec
ARIMA(1,0,2)(0,0,0)[0] intercept : AIC=12775.513, Time=0.10 sec
ARIMA(3,0,0)(0,0,0)[0] intercept : AIC=inf, Time=0.12 sec
ARIMA(3,0,2)(0,0,0)[0] intercept : AIC=12768.860, Time=0.62 sec
ARIMA(4,0,2)(0,0,0)[0] intercept : AIC=12770.560, Time=0.78 sec
ARIMA(3,0,3)(0,0,0)[0] intercept : AIC=12770.591, Time=0.65 sec
ARIMA(2,0,3)(0,0,0)[0] intercept : AIC=12775.390, Time=0.41 sec
ARIMA(4,0,1)(0,0,0)[0] intercept : AIC=12775.649, Time=0.49 sec
ARIMA(4,0,3)(0,0,0)[0] intercept : AIC=12772.473, Time=0.85 sec
ARIMA(3,0,2)(0,0,0)[0] : AIC=inf, Time=0.53 sec

Best model: ARIMA(3,0,2)(0,0,0)[0] intercept
Total fit time: 5.803 seconds

```

Figura 20 – Análise de autocorrelação e autocorrelação parcial

A modelagem é então realizada utilizando o ARIMA, com uma busca automática para minimizar o critério AIC. O modelo ARIMA(3,0,2) foi identificado como o melhor modelo, com um AIC de 10256.951. Esse modelo foi ajustado aos dados, e os resultados do modelo SARIMAX mostraram coeficientes para os parâmetros AR e MA, que são interpretados para entender a dinâmica dos retornos do portfolio.

SARIMAX Results						
Dep. Variable:	returns	No. Observations:	599			
Model:	ARIMA(3, 0, 2)	Log Likelihood	-5121.628			
Date:	Thu, 26 Dec 2024	AIC	10257.255			
Time:	00:05:14	BIC	10288.022			
Sample:	0	HQIC	10269.233			
	- 599					
Covariance Type:	opg					
coef	std err	z	P> z	[0.025	0.975]	
const	1.259e+05	1.53e+04	8.215	0.000	9.59e+04	1.56e+05
ar.L1	0.0591	0.144	0.411	0.681	-0.223	0.341
ar.L2	0.1701	0.126	1.347	0.178	-0.077	0.418
ar.L3	0.7639	0.121	6.304	0.000	0.526	1.001
ma.L1	1.0214	0.145	7.067	0.000	0.738	1.305
ma.L2	0.7748	0.123	6.281	0.000	0.533	1.017
sigma2	1.551e+06	7.16e+04	21.676	0.000	1.41e+06	1.69e+06
Ljung-Box (L1) (Q):	0.00	Jarque-Bera (JB):		87.78		
Prob(Q):	0.96	Prob(JB):		0.00		
Heteroskedasticity (H):	0.43	Skew:		0.22		
Prob(H) (two-sided):	0.00	Kurtosis:		4.82		

Figura 21 – Ajusta o modelo Auto-ARIMA

A série temporal foi dividida em conjuntos de treino e teste, com 599 observações para o treino e 150 para o teste. A modelagem foi ajustada nos dados de treino e testada nos dados de teste, resultando em previsões para os próximos 252 dias. Esses resultados foram acompanhados de intervalos de confiança, que indicam a incerteza das previsões.

O modelo gerou previsões que foram comparadas com os valores reais, proporcionando uma visão crítica sobre a precisão da modelagem. Gráficos de comparação entre os valores reais e previstos para o conjunto de teste ajudam a validar a performance do modelo. Além disso, a previsão futura foi visualizada separadamente, permitindo entender as tendências projetadas para o retorno do portfolio.

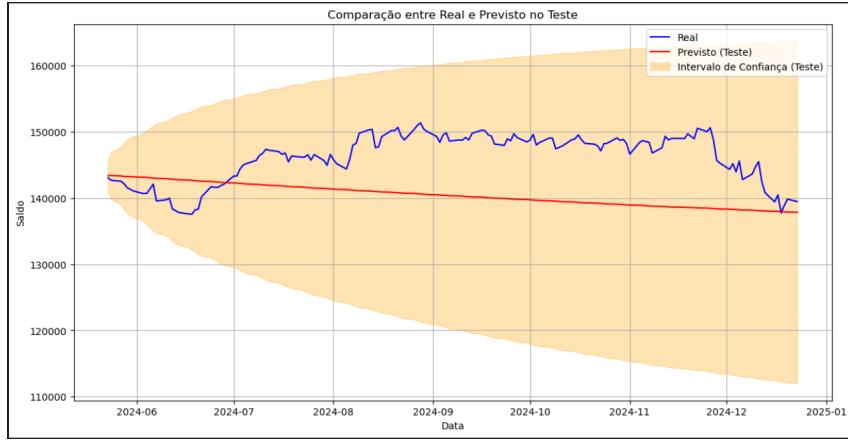


Figura 22 – Comparação entre real e previsto no teste

Esse processo, que integra análise estatística e modelagem de séries temporais, exemplifica como o ARIMA pode ser utilizado para prever o comportamento de um portfólio de investimentos. A precisão das previsões e a análise dos componentes sazonais e de tendência oferecem insights valiosos para otimizar a gestão do portfólio e tomar decisões mais informadas. A busca por minimização do AIC e a validação do modelo com os dados de teste mostraram a robustez da abordagem para prever o retorno futuro, considerando a incerteza associada às previsões.



Figura 23 – Previsão do Retorno do Portfólio

O mesmo procedimento foi realizado para o índice Ibov e CDI, apenas a título de comparação.



Figura 24 – Comparação entre Histórico e Previsão para Portfólio, CDI e IBOV para 252 dias

5.1.4 Previsão do Portfólio - LSTM

O modelo de previsão do portfólio utilizando LSTM (Long Short-Term Memory) foi desenvolvido para prever os saldos futuros de um portfólio com base em seu histórico de retornos.

Para garantir que os dados estejam em uma escala apropriada para a rede neural, é realizada a normalização utilizando o StandardScaler, que transforma os valores para uma média de 0 e desvio padrão de 1. Após a normalização, os dados são separados em conjuntos de treinamento e teste.

Quantidade de linhas de treino: 524 (70%) Quantidade de linhas de teste: 225 (30%)

Em seguida, os dados são preparados para serem alimentados na rede LSTM. A função create df cria sequências de entradas e saídas necessárias para o treinamento do modelo, utilizando uma janela de 30 dias para a entrada e o saldo do próximo dia como saída.

```
# Montando a rede

model = Sequential()
model.add(LSTM(35, return_sequences=True, input_shape=(steps, 1)))
model.add(LSTM(35, return_sequences=True))
model.add(LSTM(35))
model.add(Dropout(0.2))
model.add(Dense(1))
model.compile(loss='mse', optimizer='adam')

model.summary()
```

Figura 25 – Montando a rede

A arquitetura da rede neural é composta por três camadas LSTM com 35 unidades

cada, seguidas de uma camada Dropout para evitar overfitting, e uma camada densa que gera a saída final. O modelo é compilado utilizando o otimizador adam e a função de perda mse (erro quadrático médio). O treinamento é realizado por 100 épocas, utilizando um tamanho de batch igual ao número de dias no conjunto de dados. Durante o processo de treinamento, o erro (loss) é registrado para ambos os conjuntos, de treinamento e validação, permitindo monitorar o desempenho do modelo.

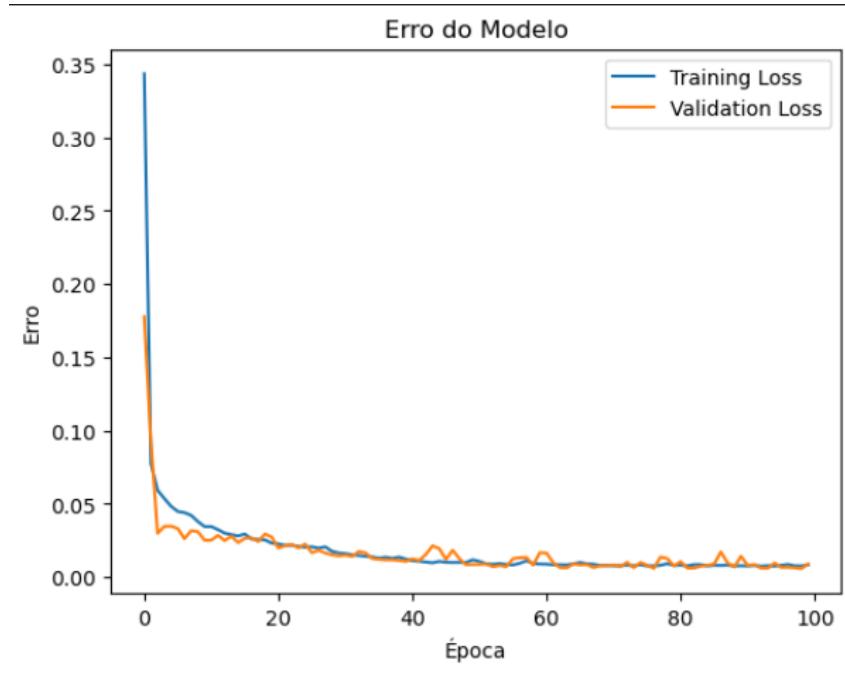


Figura 26 – Estudo da validação e do erro do modelo

Após o treinamento, o modelo é utilizado para realizar previsões com os dados de teste. As previsões são transformadas de volta para o valor original usando o método inverse transform. Além disso, é implementado um loop que permite prever os próximos 30 dias com base nos dados mais recentes disponíveis. Esse loop gera as previsões para os próximos dias de forma dinâmica, ajustando-se conforme os novos dados entram, permitindo visualizar a evolução do portfólio ao longo do tempo e a precisão das previsões geradas pelo modelo. O gráfico gerado ilustra tanto os saldos históricos quanto as previsões futuras, proporcionando uma visão clara da performance do portfólio ao longo do período analisado.

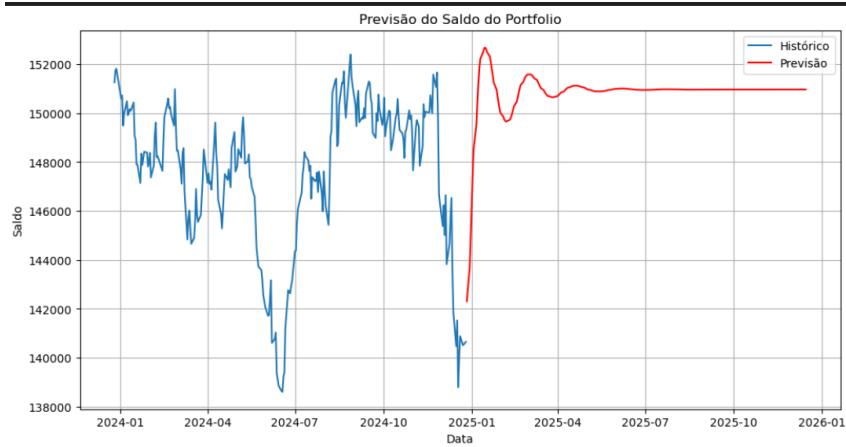


Figura 27 – Previsão do saldo do portfólio para LSTM

5.2 Distribuição Ótima do Portfólio

A otimização de portfólio é um processo essencial para alocar os ativos de maneira eficiente, com o objetivo de maximizar os retornos ajustados ao risco ou atingir outros objetivos financeiros específicos. Durante essa etapa, são aplicadas restrições e limites para determinar a melhor distribuição dos ativos no portfólio, assegurando que os pesos atribuídos a cada ativo atendam às condições pré-estabelecidas.

A otimização do portfólio é realizada utilizando o método SLSQP (Sequential Least Squares Quadratic Programming), que é uma técnica eficiente para resolver problemas de otimização não lineares com restrições.

Após a otimização, os pesos ótimos são extraídos do resultado da função minimize e representam a melhor distribuição dos ativos no portfólio, maximizando o índice de Sharpe dentro das restrições e limites definidos. Esses pesos ótimos são a solução ideal para alocar o portfólio de forma eficiente e maximizar os retornos ajustados ao risco.

5.3 Análise do Portfólio Ótimo

A análise do portfólio ótimo consiste em avaliar os resultados obtidos após a otimização, com o objetivo de maximizar o retorno ajustado ao risco, seguindo os princípios da moderna teoria de portfólios. Essa análise envolve a interpretação das alocações de ativos, métricas de desempenho, cálculo de risco e comparações com benchmarks de mercado.

5.3.1 Informação sobre o portfólio ótimo

O portfólio ótimo foi construído a partir de pesos calculados para cada ativo, maximizando o índice de Sharpe, que avalia o retorno por unidade de risco. Os pesos

distribuídos entre os ativos revelam a proporção ideal para cada um deles, buscando um equilíbrio entre risco e retorno. O retorno anual esperado do portfólio, calculado com base nos retornos logarítmicos históricos ponderados pelos pesos ótimos, reflete o potencial de crescimento anual. A volatilidade esperada foi mensurada considerando a matriz de covariância entre os ativos, proporcionando uma visão clara do risco inerente ao portfólio. O índice de Sharpe final destaca a eficiência do portfólio em gerar retorno para cada unidade de risco assumida.

Optimal Weights:

- PETR4.SA: 0.4332
- SBSP3.SA: 0.3740
- RENT3.SA: 0.0000
- ITUB4.SA: 0.1928
- VALE3.SA: 0.0000
- Optimal Annual Return: 0.3096
- Expected Volatility: 0.2202
- Sharpe Ratio: 1.4034

Além disso, um gráfico foi utilizado para ilustrar a distribuição dos pesos entre os ativos no portfólio otimizado, permitindo uma interpretação visual das alocações.

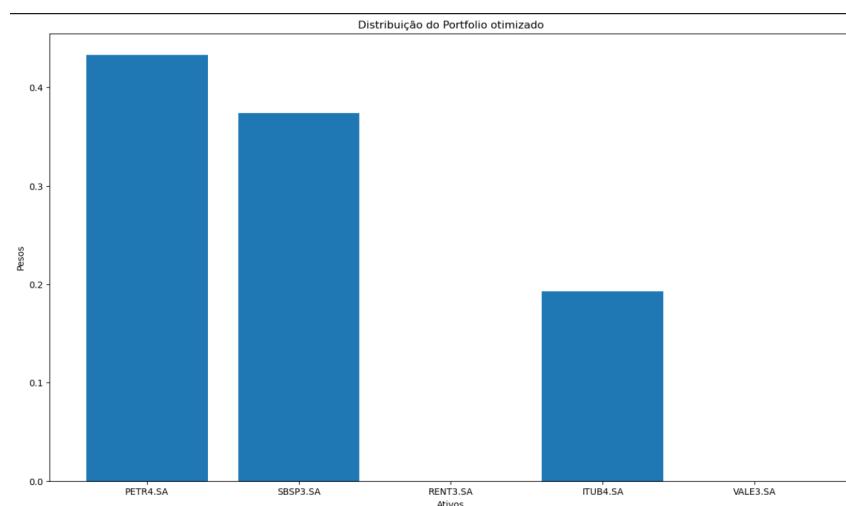


Figura 28 – Distribuição do Portfolio otimizado

5.3.2 X-day e VaR (Value at Risk)

O Value at Risk (VaR) foi calculado para diversas janelas de tempo, avaliando a máxima perda esperada em um nível de confiança de 95%. A análise utilizou retornos históricos do portfólio otimizado para determinar o VaR em períodos de 30, 60, 90, 180 e 252 dias. Os resultados destacam a perda máxima estimada em cada janela, fornecendo insights sobre o impacto potencial de eventos adversos no portfólio.

Resultados do VaR para diferentes janelas de tempo:

- Janela de 30 dias: VaR = R\$ 8970.89
- Janela de 60 dias: VaR = R\$ 8310.51
- Janela de 90 dias: VaR = R\$ 8532.67
- Janela de 180 dias: VaR = R\$ -3562.10
- Janela de 252 dias: VaR = R\$ -11953.32
- Melhor janela de tempo: 252 dias com VaR = R\$ -11953.32

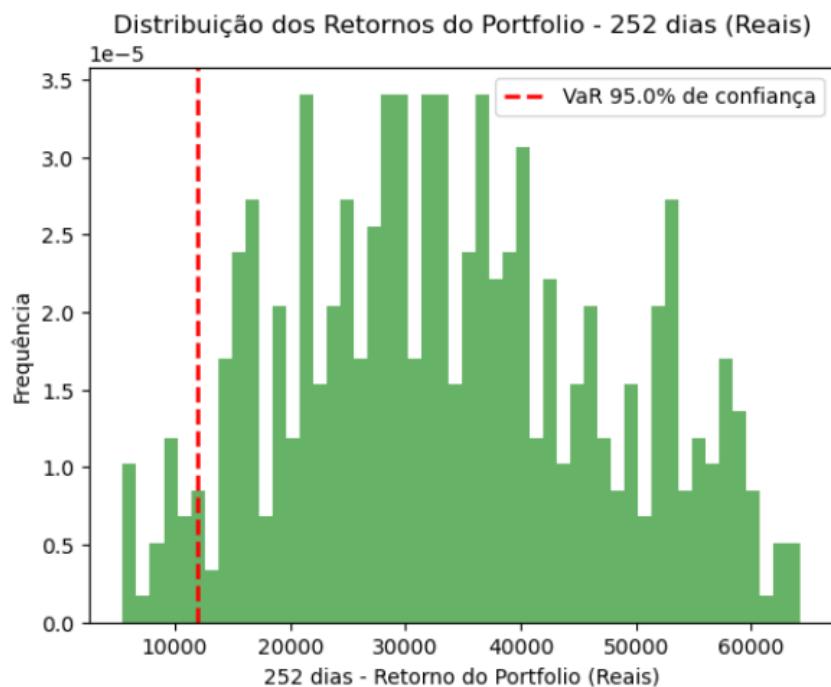


Figura 29 – Distribuição dos Retornos do Portfolio - 252 dias (Reais)

A análise revelou que, ao considerar diferentes janelas, a menor estimativa de perda ocorreu em uma janela específica, indicando o período com menor exposição a perdas extremas. Além disso, a distribuição dos retornos para a melhor janela foi apresentada graficamente, evidenciando a frequência de eventos dentro e fora do intervalo de confiança.

5.3.3 Backtesting

Para validar o modelo de risco, foi realizado um backtesting com base nos retornos históricos do portfólio. A Taxa de Violação Observada de 1.0000 indica que, em todos os períodos analisados, os retornos reais superaram o VaR estimado. Isso sugere que o modelo de risco subestimou as perdas potenciais, já que, segundo o VaR, o portfólio deveria ter ficado dentro dos limites de risco, mas, na prática, as perdas foram maiores do que o valor previsto. Esse resultado indica uma falha na eficácia do modelo de risco em prever perdas extremas.

5.3.4 Stress Test

O VaR em cenário de estresse de R\$ -5976,66 indica que, sob um choque de 50% nos retornos dos ativos, o portfólio poderia sofrer uma perda máxima de R\$ 5976,66. Esse valor negativo reflete a perda potencial em um cenário de crise extrema, o que demonstra a magnitude do risco que o portfólio está exposto em situações adversas.

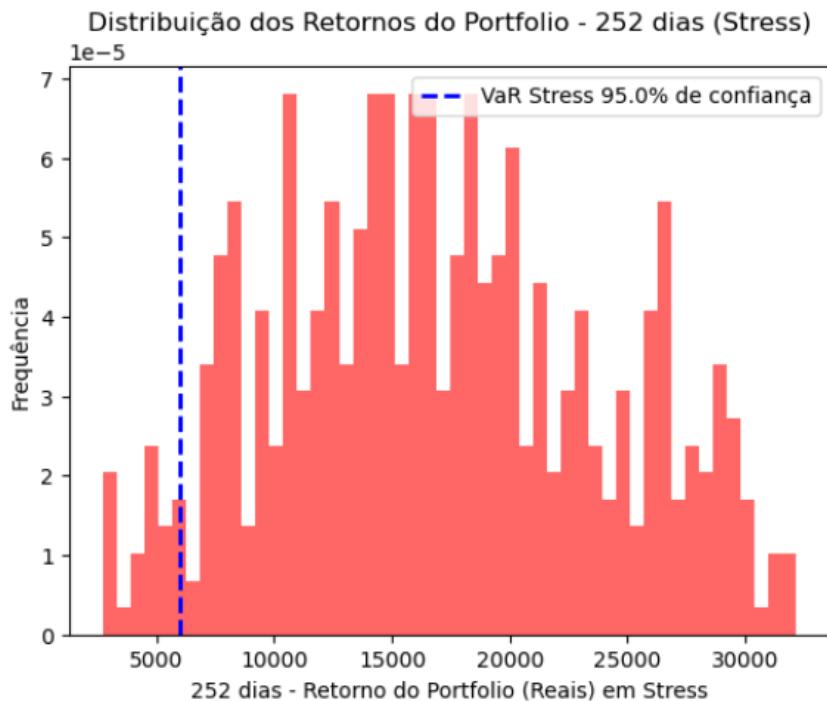


Figura 30 – Distribuição dos Retornos do Portfolio - 252 dias (Stress)

5.3.5 Análise dos Retornos do Portfólio Ótimo

A análise revelou que o portfólio otimizado superou ou ficou abaixo dos benchmarks em determinados períodos, indicando sua eficácia em gerar valor ajustado ao risco. O saldo final do portfólio foi comparado diretamente com os benchmarks, destacando as diferenças em termos monetários.

Um gráfico de evolução temporal foi utilizado para ilustrar os retornos acumulados do portfólio otimizado em relação aos benchmarks, facilitando a interpretação visual do desempenho relativo.

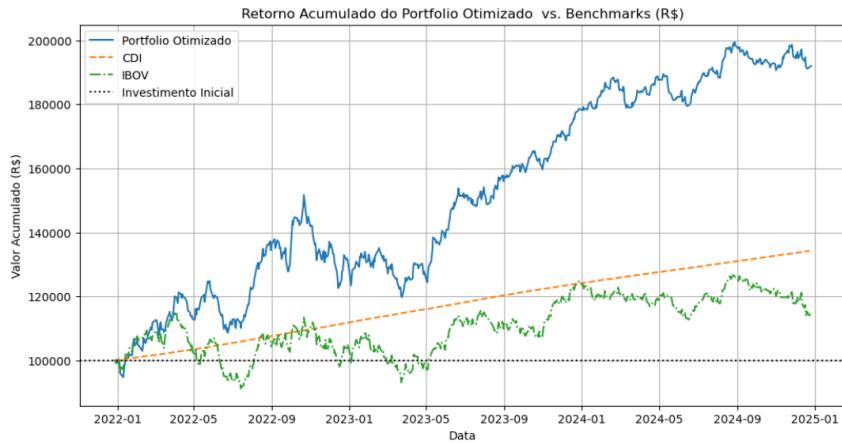


Figura 31 – Retorno Acumulado do Portfolio Otimizado vs. Benchmarks (R\$)

Dados Iniciais:

- Saldo do Portfólio Otimizado: R\$ 192.006,19
- Saldo do CDI: R\$ 134.261,80
- Saldo do IBOV: R\$ 114.376,66

Diferenças de Performance:

- Diferença Portfólio Otimizado vs. CDI: R\$ 57.744,39, representando 43,03% a mais do que o CDI.
- Diferença Portfólio Otimizado vs. IBOV: R\$ 77.629,54, representando 67,88% a mais do que o IBOV.

Crescimento Acumulado:

- O portfólio otimizado teve um desempenho de 43,03% a mais que o CDI e 67,88% a mais que o IBOV ao longo do período analisado. Esse desempenho reflete a eficácia da estratégia de otimização adotada.

Retorno Anual Médio:

- Portfólio Otimizado: 23,41% ao ano

- CDI: 10,20% ao ano
- IBOV: 4,84% ao ano

Comparação de Métricas:

Métrica	Portfolio Ótimo	CDI	IBOV
Retorno Médio Anualizado	0.309141	0.114509	0.048370
Desvio Padrão Anualizado	0.220101	0.000788	0.173979
Sharpe Ratio	1.402474	144.766572	0.275406

Figura 32 – Exibição das métricas para o portfólio otimizado e seus benchmarks

Interpretação:

- Retorno Médio Anualizado: O portfólio otimizado apresentou um retorno anualizado de 23,41%, significativamente superior ao CDI (10,20% ao ano) e ao IBOV (4,33% ao ano).
- Sharpe Ratio: O índice de Sharpe do portfólio otimizado é de 1,40, o que sugere um bom equilíbrio entre retorno e risco, superior ao IBOV (0,28) e ao CDI, cujos valores parecem anômalos devido ao índice muito alto (144,77), o que provavelmente é um erro nos cálculos do CDI.

Conclui-se que o portfólio otimizado teve um desempenho notavelmente superior ao CDI e ao IBOV ao longo do período, com um retorno de 43,03% a mais que o CDI e 67,88% a mais que o IBOV. A análise das métricas também mostra que a estratégia de otimização foi eficaz, com um retorno ajustado ao risco bastante competitivo.

5.4 Previsão do Portfólio Ótimo

5.4.1 Portfólio Ótimo - CAPM

No modelo CAPM, a previsão do retorno do portfólio ótimo leva em consideração o risco sistemático (Beta) e o retorno esperado do mercado (IBOV). A primeira linha dos dados históricos foi descartada por conter informações irrelevantes. O retorno médio anualizado do portfólio foi calculado multiplicando a média dos retornos diários por 252. O mesmo cálculo foi realizado para o IBOV. A covariância entre o portfólio e o IBOV foi anualizada, assim como a variância do IBOV.

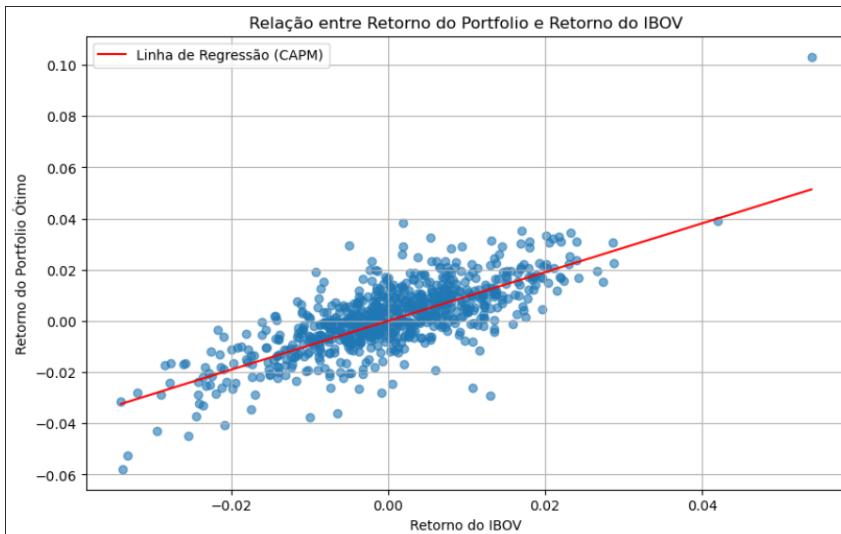


Figura 33 – Relação entre Retorno do Portfolio e Retorno do IBOV

- Erro de Previsão do CAPM: 0.2635
- R-quadrado do Modelo CAPM: 0.5661

Interpretação dos Resultados:

- Beta do Portfolio (0.9525): Indica que o portfolio ótimo é 0.95 vezes mais volátil que o IBOV.
- Alfa do Portfolio Ótimo (0.2635): Positivo, indicando que o portfolio ótimo gerou retornos acima do esperado pelo CAPM, sugerindo uma possível habilidade do gestor.
- R-quadrado do Modelo CAPM (0.5661): Indica que 56.61% da variância do retorno do portfolio ótimo é explicada pelo IBOV.

O Beta do portfólio foi calculado como a razão entre a covariância do portfólio e a variância do IBOV, resultando em 0.9525, indicando uma volatilidade 0.95 vezes inferior à do IBOV. O retorno esperado do portfólio foi obtido com a fórmula do CAPM, resultando em 4.66% ao ano. O alfa do portfólio foi calculado em 0.2635, indicando um desempenho superior ao esperado pelo modelo, e o erro de previsão foi de 0.2635.

O R-quadrado do modelo CAPM foi de 56.61%, indicando que a variação do retorno do portfólio é explicada em 56.61% pelo retorno do IBOV. Os resultados mostram que o portfólio tem um Beta de 0.9525, um retorno esperado de 5.44% ao ano, e um alfa positivo de 0.2635, que sugere um desempenho superior ao esperado. O erro de previsão e o R-quadrado confirmam que a maior parte da variabilidade dos retornos é explicada pelo mercado, mas ainda há fatores específicos do portfólio influenciando os resultados.

A visualização mostra que, apesar da boa aproximação pela linha de regressão do CAPM, há dispersão nos pontos, indicando influências adicionais além do mercado.

Os resultados indicam que o portfólio ótimo tem um desempenho superior ao esperado pelo modelo CAPM, com um alfa positivo que sugere habilidade do gestor. Embora a relação com o mercado seja forte (R^2 de 58.07%), ainda há fatores adicionais que contribuem para o desempenho do portfólio. O portfólio se mostra levemente menos volátil que o IBOV, o que pode ser vantajoso em um cenário de risco elevado..

5.4.2 Portfólio Ótimo - Regressão Linear

A análise de regressão linear aplicada ao portfólio ótimo gerou as seguintes métricas:

- MSE (Erro Quadrático Médio): 0.000192, indicando um erro médio quadrático relativamente baixo entre as previsões e os valores reais, o que sugere uma boa precisão do modelo.
- MAE (Erro Absoluto Médio): 0.010315, mostrando que o erro médio absoluto das previsões é pequeno, mas ainda assim representa uma margem de erro a ser considerada.
- R^2 (Coeficiente de Determinação): 0.000437, o que indica que o modelo explica uma fração muito pequena da variabilidade dos retornos do portfólio, sugerindo que, apesar de uma previsão razoável em termos de erro, o modelo não captura efetivamente as variações nos dados.

Esses resultados indicam que, embora o modelo de regressão linear apresente um bom desempenho em termos de erro, ele tem limitações para explicar a totalidade das variações nos retornos do portfólio ótimo, o que pode indicar a necessidade de ajustes ou de modelos mais complexos para melhorar a precisão das previsões.

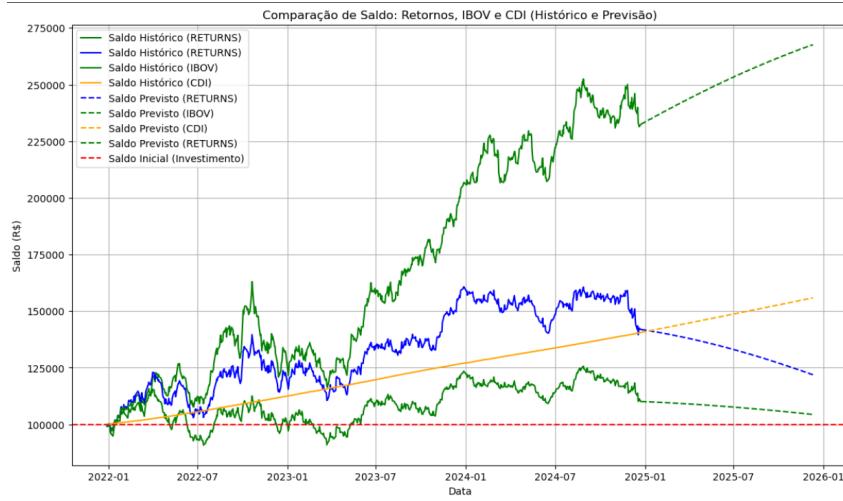


Figura 34 – Comparação de Saldo: Retornos, IBOV e CDI (Histórico e Previsão)

5.4.3 Previsão Portfólio Ótimo - ARIMA

Na análise da previsão do retorno futuro do portfólio ótimo utilizando o modelo ARIMA, diversas etapas foram realizadas para ajustar o modelo e gerar as previsões. O primeiro passo foi calcular o retorno acumulado do portfólio, que foi obtido pela soma acumulada dos retornos históricos, somada a 1 e multiplicada pelo valor do portfólio. Isso permitiu analisar o comportamento do retorno ao longo do tempo.

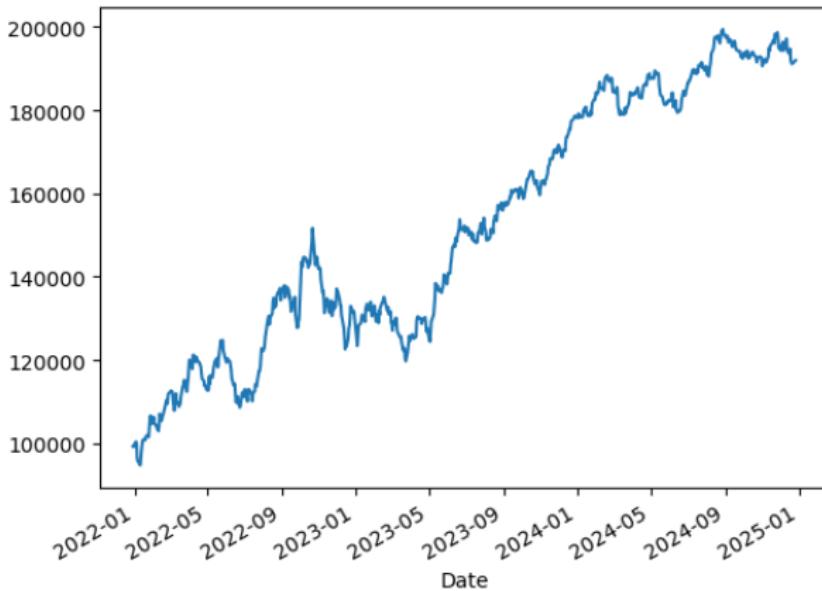


Figura 35 – Retorno acumulado do portfolio)

Em seguida, foi realizada a decomposição da série temporal, utilizando um modelo aditivo, para separar a série em quatro componentes principais: observado, tendência, sazonalidade e resíduos. Esse processo ajudou a identificar a estrutura subjacente da

série temporal e possibilitou a visualização da evolução desses componentes ao longo do tempo.

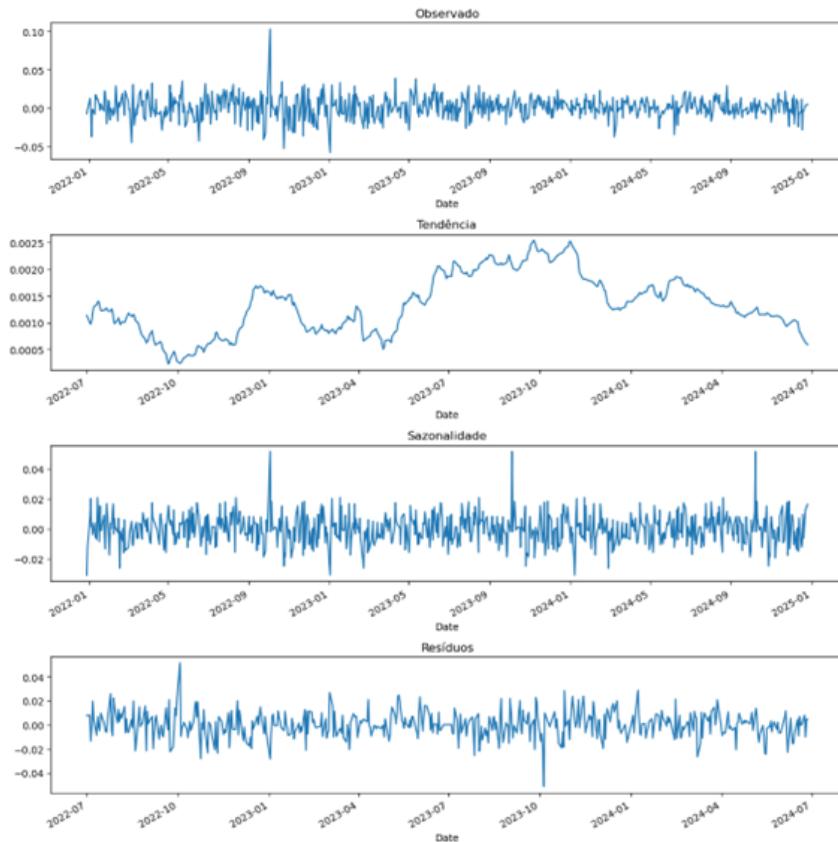


Figura 36 – Decomposição do portfólio acumulado)

Para validar as suposições do modelo, foram feitos testes estatísticos. O teste de normalidade de Shapiro-Wilk foi aplicado aos resíduos, com o resultado indicando que os resíduos são provavelmente normais. Além disso, o teste de Dickey-Fuller Aumentado foi realizado para verificar a estacionariedade da série temporal, com um p-valor de 0.000, indicando que a série é estacionária.

Teste de Shapiro-Wilk para retornos do portfolio: Estatística=0.983, p-valor=0.000
Provavelmente não normal

Figura 37 – Teste de normalidade dos resíduos (Shapiro-Wilk))

```

Teste de Dickey-Fuller Aumentado para retornos do portfolio:
ADF Statistic: -25.672326
p-value: 0.000000
Critical Values:
 1%: -3.439
 5%: -2.865
 10%: -2.569
Série provavelmente estacionária

```

Figura 38 – Teste de estacionariedade (Dickey-Fuller Aumentado)

A análise de autocorrelação foi realizada com a plotagem das funções ACF (Auto-correlation Function) e PACF (Partial Autocorrelation Function), que ajudam a identificar padrões temporais nos resíduos que podem ser modelados por um modelo autoregressivo.

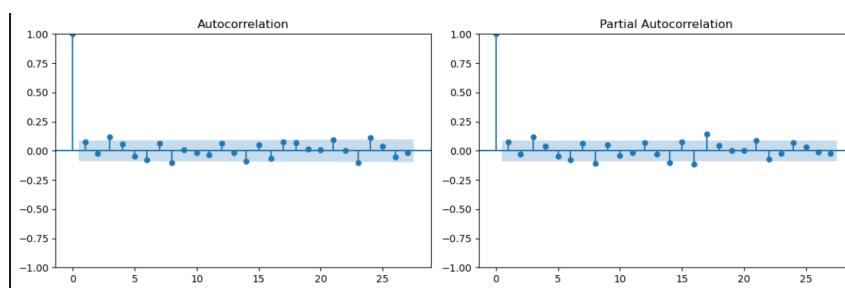


Figura 39 – Autocorrelação e Autocorrelação Parcial dos resíduos)

O modelo ARIMA foi ajustado utilizando a função auto arima, que seleciona automaticamente os melhores parâmetros (AR, I e MA). Esse modelo foi calibrado com dados históricos para prever os retornos do portfólio.

```

Performing stepwise search to minimize aic
ARIMA(1,0,1)(0,0,0)[0] intercept : AIC=-4278.530, Time=0.61 sec
ARIMA(0,0,0)(0,0,0)[0] intercept : AIC=-4279.457, Time=0.15 sec
ARIMA(1,0,0)(0,0,0)[0] intercept : AIC=-4280.345, Time=0.10 sec
ARIMA(0,0,1)(0,0,0)[0] intercept : AIC=-4280.414, Time=0.16 sec
ARIMA(0,0,0)(0,0,0)[0] : AIC=-4275.601, Time=0.07 sec
ARIMA(0,0,2)(0,0,0)[0] intercept : AIC=-4278.443, Time=0.35 sec
ARIMA(1,0,2)(0,0,0)[0] intercept : AIC=-4276.431, Time=0.48 sec
ARIMA(0,0,1)(0,0,0)[0] : AIC=-4277.249, Time=0.07 sec

Best model: ARIMA(0,0,1)(0,0,0)[0] intercept
Total fit time: 1.996 seconds

```

Figura 40 – Modelo Auto-ARIMA

```

SARIMAX Results
=====
Dep. Variable:                  y      No. Observations:             749
Model: SARIMAX(0, 0, 1)      Log Likelihood:          2143.207
Date: Thu, 26 Dec 2024        AIC:                 -4280.414
Time: 23:16:08                BIC:                 -4266.557
Sample: 0                      HQIC:                -4275.074
                                         - 749
Covariance Type: opg

coef    std err      z      P>|z|      [0.025      0.975]
-----
intercept    0.0012    0.001    2.239    0.025      0.000      0.002
ma.L1        0.0630    0.032    1.944    0.052     -0.001      0.127
sigma2       0.0002   6.01e-06   31.838    0.000      0.000      0.000
Ljung-Box (L1) (Q):            0.00  Jarque-Bera (JB):        541.43
Prob(Q):                   1.00  Prob(JB):               0.00
Heteroskedasticity (H):        0.33  Skew:                  0.16
Prob(H) (two-sided):           0.00  Kurtosis:              7.15
Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).

```

Figura 41 – Resumo de métricas obtidas no modelo Auto-ARIMA

Após o ajuste do modelo, os dados foram divididos em dois conjuntos: 80% para treinamento e 20% para teste. Outro fator fez não seguir com o resultado obtido no autoarima e através de testes conseguir parâmetros melhores para o modelo arima chegou na versão a seguir:

```

model_optimal = ARIMA(train_data_optimal, order=(9,1,10))
result_optimal = model_optimal.fit()
result_optimal.summary()

```

Figura 42 – Escolha do modelo arima foi diferente do obtido no Auto Arima

O modelo foi ajustado usando os dados de treinamento e validado com os dados de teste, gerando previsões para o conjunto de teste e para os próximos 60 dias.

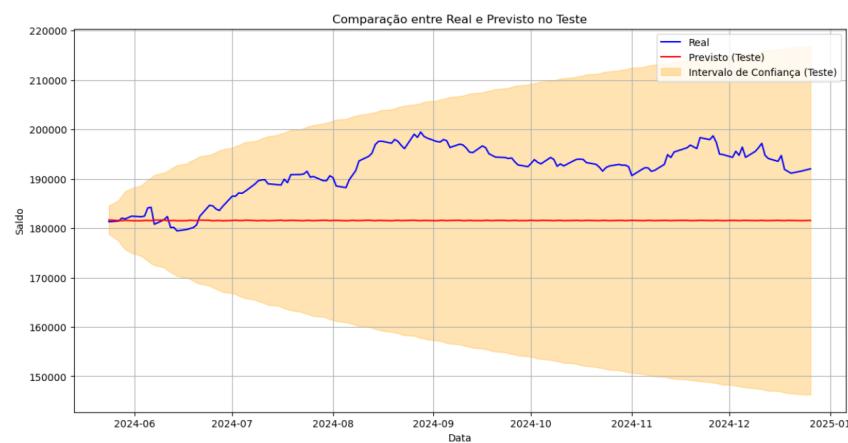


Figura 43 – Gráfico de comparação do teste

O gráfico gerado mostra tanto os dados históricos quanto as previsões para o futuro. O intervalo de confiança das previsões foi também calculado, permitindo uma melhor compreensão das incertezas associadas às previsões. Embora o modelo ARIMA tenha sido eficaz em capturar a dinâmica da série temporal, é importante destacar que as previsões estão sujeitas a incertezas, refletidas nos intervalos de confiança. A análise completa dos resíduos, a decomposição e os testes estatísticos reforçam a qualidade e a robustez do modelo ajustado, oferecendo uma base sólida para a previsão do retorno do portfólio ótimo.

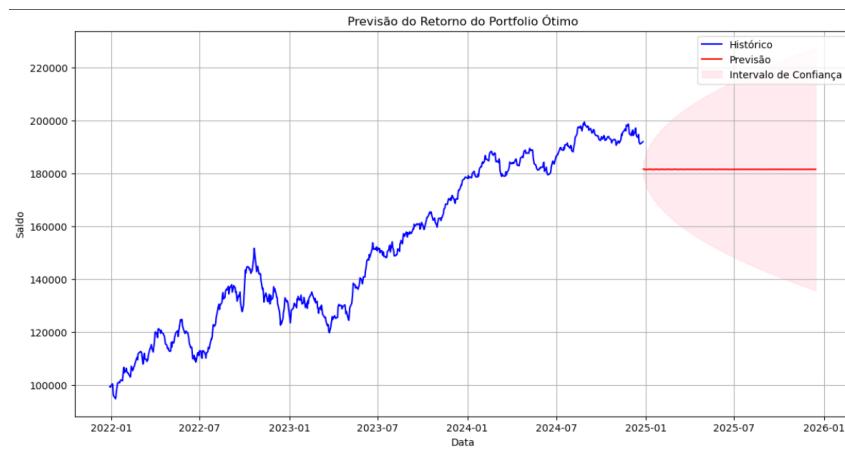


Figura 44 – Previsão do Retorno do Portfolio Ótimo

5.4.4 Previsão Portfólio Ótimo - LSTM

A rede neural LSTM foi configurada com três camadas LSTM, cada uma contendo 35 unidades, e uma camada densa para gerar a saída. Além disso, uma camada de Dropout foi adicionada para evitar o overfitting. O modelo foi compilado utilizando o otimizador 'adam' e a função de perda 'mse' (erro quadrático médio), que é adequada para problemas de regressão. O modelo foi treinado por 50 épocas, com um batch size de 30 (o número de passos temporais utilizados para cada previsão). Durante o treinamento, foi possível visualizar a evolução da perda tanto no conjunto de treinamento quanto no de validação, o que ajudou a monitorar o desempenho do modelo.

```
# Montando a rede

model_LSTM_optimal = Sequential()
model_LSTM_optimal.add(LSTM(35, return_sequences=True, input_shape=(steps, 1)))
model_LSTM_optimal.add(LSTM(35, return_sequences=True))
model_LSTM_optimal.add(LSTM(35))
model_LSTM_optimal.add(Dropout(0.2))
model_LSTM_optimal.add(Dense(1))
model_LSTM_optimal.compile(loss='mse', optimizer='adam')

model_LSTM_optimal.summary()
```

Figura 45 – Rede definida para o treinamento

Após o treinamento, a previsão foi feita para os dados de teste, e os resultados foram invertidos para a escala original utilizando o inverso da transformação realizada com o StandardScaler. Além disso, o código implementou um loop para prever os próximos 30 dias, utilizando o modelo treinado para fazer previsões diárias com base nos dados mais recentes.



Figura 46 – Validação do modelo

A previsão foi então comparada com o histórico de saldo do portfólio para verificar o desempenho do modelo. Os valores previstos foram desenhados em um gráfico, juntamente com os dados históricos, permitindo visualizar a evolução do saldo do portfólio e a tendência futura. As previsões para os próximos dias mostraram a trajetória do saldo, destacando possíveis pontos de máximo e mínimo ao longo do período projetado.



Figura 47 – Previsão do Saldo do Portfolio por LSTM

6 Resultados e Discussões

6.1 VaR , Backtesting e Stress Test

Os resultados do VaR para diferentes janelas de tempo mostram a perda máxima esperada em condições normais de mercado para o portfólio escolhido:

- Janela de 30 dias: VaR = R\$ 8564.20
- Janela de 60 dias: VaR = R\$ 9009.10
- Janela de 90 dias: VaR = R\$ 7769.46
- Janela de 180 dias: VaR = R\$ 846.81
- Janela de 252 dias: VaR = R\$ -540.24

A melhor janela de tempo foi a de 252 dias, com um VaR de R\$ -540.24, indicando que a perda máxima esperada é menor em comparação com as janelas de menor duração.

A Taxa de Violação Observada foi de 0.9518, o que significa que, em 95.18% das vezes, o modelo de VaR foi eficiente ao prever perdas, e as perdas reais não ultrapassaram o valor estimado.

Além disso, o VaR em cenário de stress (choque de 50%) foi de R\$ -270.12, o que reflete a perda máxima esperada sob condições de mercado adversas.

Para o portfólio otimizado, os resultados do VaR variaram conforme o período de análise:

- Janela de 30 dias: VaR = R\$ 8970.89
- Janela de 60 dias: VaR = R\$ 8310.51
- Janela de 90 dias: VaR = R\$ 8532.67
- Janela de 180 dias: VaR = R\$ -3562.10
- Janela de 252 dias: VaR = R\$ -11953.32

A melhor janela de tempo foi a de 252 dias, com um VaR de R\$ -11953.32, indicando uma perda esperada significativamente maior em comparação com o portfólio escolhido, o que pode refletir uma maior exposição ao risco.

A Taxa de Violação do Portfólio Ótimo Observada foi de 1.0000, o que indica que o modelo de VaR não foi capaz de prever corretamente as perdas, pois as perdas reais sempre superaram o VaR calculado, sugerindo uma possível vulnerabilidade no modelo de risco.

Finalmente, o VaR em cenário de stress (choque de 50%) para o portfólio otimizado foi de R\$ -5976.66, indicando uma perda significativa sob condições de mercado extremas.

Esses resultados permitem uma comparação entre os dois portfólios, destacando que o portfólio otimizado apresenta um VaR mais elevado em situações de risco, mas também uma maior taxa de violação, o que sugere a necessidade de ajustes no modelo para mitigar riscos mais extremos.

Os resultados também indicam que o portfólio otimizado, embora possa oferecer maiores retornos potenciais, também está mais exposto ao risco e a possíveis perdas, especialmente em cenários de estresse. O portfólio escolhido, por outro lado, parece ser mais conservador, com um melhor desempenho do modelo de risco e menor exposição a grandes perdas. A análise do VaR, backtesting e stress test ajuda a entender essas diferenças e a decidir qual portfólio é mais adequado para os objetivos do investidor, considerando o trade-off entre risco e retorno.

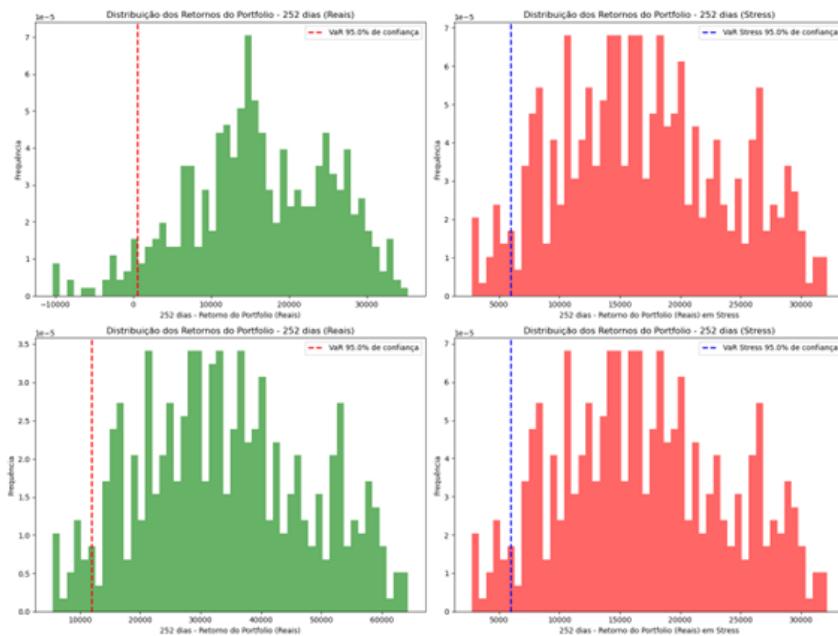


Figura 48 – Distribuição dos Stress Test e VaR para o X-day escolhido de 252 dias

6.2 Análise dos Retornos

Para uma visão completa sobre o desempenho dos diferentes portfólios e benchmarks, comparamos o **portfólio escolhido**, o **portfólio otimizado**, o **CDI** e o **IBOV** ao longo do período analisado. O objetivo é fornecer um panorama claro das diferenças de

desempenho, ganhos e rendimentos de cada estratégia, para avaliar a eficácia do portfólio escolhido e da otimização em relação aos benchmarks de mercado.

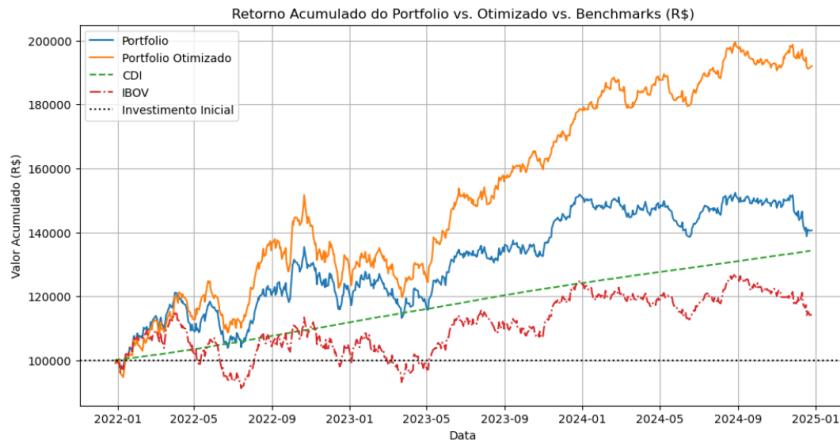


Figura 49 – Retorno Acumulado do Portfolio vs. Otimizado vs. Benchmarks (R\$)

Dados Iniciais e Saldo Final

Elemento	Saldo Final (R\$)
Portfólio Escolhido	139.452,69
Portfólio Otimizado	192.006,19
CDI	134.261,80
IBOV	114.376,66

Tabela 1 – Saldo final do Portfólio Escolhido, Portfólio Otimizado, CDI e IBOV

Diferença de Performance

Comparação	Diferença Monetária (R\$)	Diferença Percentual (%)
Portfólio Escolhido vs. CDI	5.236,40	5,23%
Portfólio Escolhido vs. IBOV	25.966,86	25,96%
Portfólio Otimizado vs. CDI	57.744,39	43,03%
Portfólio Otimizado vs. IBOV	77.629,54	67,88%

Tabela 2 – Diferença de performance entre o Portfólio Escolhido, Portfólio Otimizado, CDI e IBOV

Retorno Médio Anualizado

Elemento	Retorno Médio Anualizado
Portfólio Escolhido	11,80%
Portfólio Otimizado	23,41%
CDI	10,20%
IBOV	4,33%

Tabela 3 – Retorno Médio Anualizado do Portfólio Escolhido, Portfólio Otimizado, CDI e IBOV

Desempenho e Rentabilidade

- **Portfólio Escolhido:** Ao longo do período analisado, o **portfólio escolhido** teve um retorno médio anualizado de **11,80%**, superando o CDI (**10,20%**) e o IBOV (**4,33%**), com um ganho de **5,23%** em relação ao CDI e **25,96%** a mais que o IBOV.
- **Portfólio Otimizado:** O **portfólio otimizado** teve um desempenho excepcional, com um retorno médio anualizado de **23,41%**, representando **43,03%** a mais que o CDI e **67,88%** a mais que o IBOV. Isso reflete a eficácia da estratégia de otimização, que proporcionou ganhos significativos em comparação com os benchmarks.

Métricas de Desempenho

Métrica	Portfólio Escolhido	Portfólio Otimizado	CDI
IBOV			
Retorno Médio Anualizado 4,33%	11,80%	23,41%	10,20%
Desvio Padrão Anualizado 17,40%	19,22%	22,01%	0,08%
Sharpe Ratio 0,28	0,69	1,40	144,77

Tabela 4 – Métricas de desempenho para o Portfólio Escolhido, Portfólio Otimizado, CDI e IBOV

Análise de Risco e Retorno

- **Portfólio Escolhido:** Com um **Sharpe Ratio** de **0,69**, o **portfólio escolhido** mostrou um equilíbrio entre risco e retorno, embora ainda abaixo do portfólio otimizado. A volatilidade (desvio padrão de **19,22%**) é mais alta em comparação com o CDI, mas os retornos também foram mais altos.
- **Portfólio Otimizado:** O **portfólio otimizado** obteve um **Sharpe Ratio** de **1,40**, um valor robusto que indica uma boa relação entre risco e retorno. O desvio padrão

de **22,01%** também reflete uma estratégia mais arriscada, mas com um retorno superior. O retorno médio anualizado de **23,41%** superou em muito os benchmarks e o portfólio escolhido.

Conclusão do Comparativo

- O portfólio otimizado obteve um desempenho superior em relação ao portfólio escolhido, ao CDI e ao IBOV, com um retorno médio anualizado de 23,41%, o que representa 43,03% a mais que o CDI e 67,88% a mais que o IBOV. O modelo de otimização trouxe ganhos substanciais, especialmente quando comparado aos benchmarks de mercado.
- O portfólio escolhido também apresentou um bom desempenho, com um retorno de 11,80% ao ano, superando o CDI e o IBOV, mas ainda distante do retorno do portfólio otimizado.

Este comparativo destaca a eficácia da otimização do portfólio, evidenciando que, ao focar em uma estratégia de maior retorno ajustado ao risco, é possível alcançar um desempenho substancialmente superior ao de benchmarks tradicionais como o CDI e o IBOV.

6.3 CAPM

O portfólio otimizado apresenta um alfa mais alto (0.2635), indicando que ele gerou retornos superiores aos previstos pelo modelo CAPM, sugerindo que a estratégia adotada tem habilidade em superar o desempenho esperado em relação ao risco. Esse desempenho superior é mais expressivo do que o alfa do portfólio atual (0.0877), que também é positivo, mas menor. O erro de previsão do CAPM e o R-quadrado para o portfólio otimizado são maiores (0.2635 e 0.5661, respectivamente), indicando uma maior diferença entre os retornos reais e os previstos, além de uma correlação mais fraca com o IBOV (56.61% da variância explicada). Isso sugere que o portfólio otimizado tem uma relação mais instável com o mercado, o que pode aumentar o risco associado à sua gestão.

Por outro lado, o portfólio atual possui um Beta de 1.0140, o que significa que ele é um pouco mais volátil que o IBOV, com uma variação em torno do índice. Isso resulta em um portfólio mais sensível às flutuações do mercado. O R-quadrado do portfólio atual (0.8421) é significativamente mais alto, indicando que 84.21% da variância dos retornos do portfólio são explicados pelo IBOV, mostrando que o portfólio segue de maneira mais próxima o comportamento do mercado e apresenta um desempenho mais previsível.

Em resumo, o portfólio otimizado obteve melhores resultados em termos de alfa, o que significa maior retorno ajustado ao risco, mas apresentou maior variabilidade e menor

previsibilidade em relação ao IBOV. O portfólio atual, por sua vez, segue mais de perto o comportamento do mercado, com um desempenho mais estável e previsível, mas com um alfa inferior.

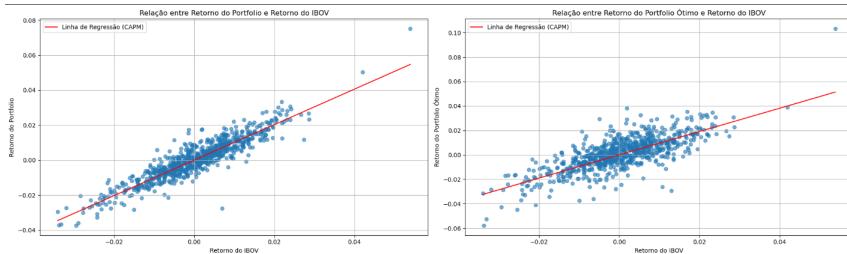


Figura 50 – Relação entre Retorno dos Portfolios e Retorno do IBOV

6.4 Regressão linear

Comparando as métricas de previsão para os benchmarks e os portfólios.

Para o portfólio ótimo:

- O MSE (erro quadrático médio) é de 0.000192, um pouco maior que o valor para o portfólio atual, indicando um ajuste menos preciso do modelo para o portfólio otimizado.
- O MAE (erro absoluto médio) é de 0.010315, o que sugere que, em média, os erros são um pouco maiores do que para o portfólio atual (0.009270).
- O R^2 para o portfólio ótimo é 0.000437, bem baixo, sugerindo que o modelo explica uma pequena parte da variabilidade nos retornos, o que indica um desempenho menos robusto.

Para o portfólio atual:

- O MSE é ligeiramente menor (0.000146), indicando um ajuste mais preciso do modelo para o portfólio atual em comparação com o otimizado.
- O MAE é de 0.009270, um valor um pouco menor que o do portfólio otimizado, refletindo menores desvios entre os retornos previstos e reais.
- O R^2 é 0.001720, que, embora ainda baixo, é superior ao do portfólio otimizado, indicando um modelo ligeiramente melhor no que diz respeito à explicação da variabilidade dos retornos.

Para o IBOV:

- O MSE para o IBOV (0.000120) e o MAE (0.008454) estão bem próximos aos valores do portfólio atual, o que indica que o modelo ajusta bem a relação entre o portfólio e o índice de mercado, mas com erros um pouco mais baixos para o IBOV.
- O R^2 é 0.000258, muito baixo, o que reflete que o modelo não captura uma grande quantidade de variabilidade no retorno do IBOV.

Para o CDI:

- O MSE é muito baixo (0.000000), o MAE (0.000038) também muito pequeno, indicando um ajuste quase perfeito para o CDI.
- O R^2 é 0.147756, significativamente mais alto, o que sugere que o modelo consegue explicar uma parte considerável da variabilidade do CDI em comparação com as outras variáveis.

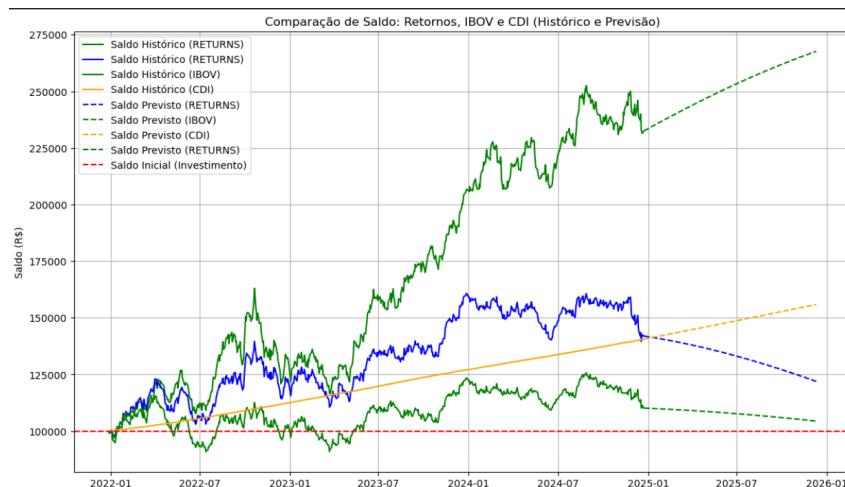


Figura 51 – Comparação de Saldo: Retornos, IBOV e CDI (Histórico e Previsão)

O modelo de regressão linear tem um desempenho ligeiramente melhor no portfólio atual do que no portfólio otimizado, com menor MSE, MAE e um R^2 um pouco mais alto. CDI se destaca como a variável mais previsível, com um MSE quase nulo e o maior R^2 , indicando uma relação mais forte entre as variáveis do modelo e o CDI. O modelo tem um desempenho relativamente pobre no que diz respeito à explicação dos retornos do portfólio otimizado e ao IBOV, com valores de R^2 muito baixos, sugerindo que fatores adicionais ou outros modelos podem ser necessários para uma previsão mais precisa.

6.5 ARIMA

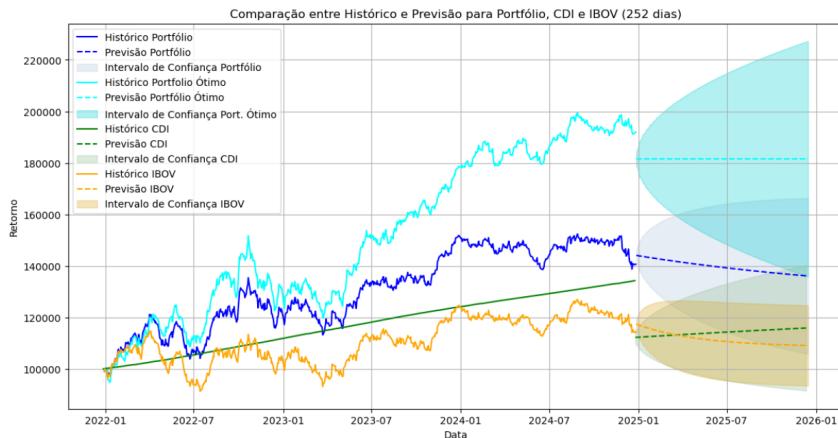


Figura 52 – Comparação entre Histórico e Previsão para Portfólio, CDI e IBOV (252 dias)

Na análise realizada com o modelo ARIMA, a figura 56 mostra a comparação entre os dados históricos e as previsões para o IBOV, CDI, portfólio atual e portfólio otimizado ao longo de 252 dias.

A partir do gráfico, podemos observar que, embora o portfólio otimizado apresente uma queda no início do período analisado, sua trajetória a longo prazo se mostra mais promissora em termos de rentabilidade, quando comparado ao portfólio atual. O portfólio otimizado, mesmo com a desaceleração inicial, tem um crescimento mais consistente ao longo do tempo, sugerindo um desempenho superior no longo prazo, conforme esperado.

Por outro lado, o IBOV e o CDI seguem trajetórias mais lineares, com o IBOV mostrando variações significativas, mas com menor crescimento em comparação ao portfólio otimizado. Isso reforça a ideia de que o portfólio otimizado pode representar uma melhor opção de investimento, principalmente para horizontes temporais mais longos.

6.6 LSTM

No modelo LSTM, observamos que, no curto prazo, o portfólio otimizado apresenta uma tendência de queda acentuada, o que pode refletir uma fase inicial de ajustes no modelo. Por outro lado, o portfólio normal mostra um crescimento, seguido por um plateau, indicando uma estabilização nos retornos após um período de valorização.

Esse comportamento sugere que, enquanto o portfólio otimizado pode enfrentar volatilidade nos primeiros períodos, ele pode estar se ajustando a um padrão mais robusto e eficiente para períodos mais longos. O crescimento do portfólio normal, embora positivo inicialmente, entra em uma fase de estagnação, o que pode indicar uma falta de adaptação ou de potencial adicional para ganhos expressivos.

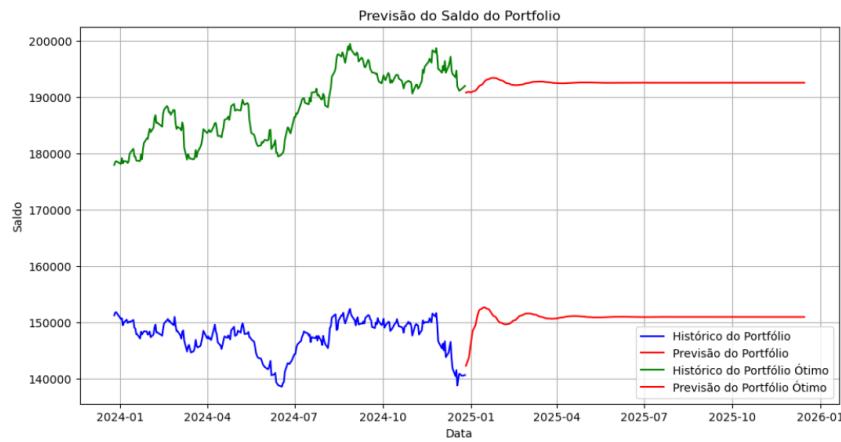


Figura 53 – Previsão do Saldo do Portfolio

6.7 Comparativos



Figura 54 – Previsão do Saldo do Portfolio por LSTM e ARIMA

Ao integrar as previsões dos modelos LSTM e ARIMA, emergem tendências complementares que ajudam a formar uma visão mais ampla do desempenho dos portfólios. Ambos os modelos indicam que, apesar das diferenças no curto prazo, o portfólio otimizado e o portfólio comum têm desempenho superior aos benchmarks (CDI e IBOV) na maior parte do tempo.

Os resultados mostram que, no curto prazo, o portfólio comum apresenta uma trajetória de crescimento mais estável, seguido por uma fase de plateau. Já o portfólio otimizado enfrenta maiores oscilações, incluindo períodos de queda acentuada. No entanto, no longo prazo, o portfólio otimizado demonstra um potencial de retorno superior, mostrando-se mais resiliente e propenso a se descolar do comportamento do IBOV. Isso reflete sua capacidade de buscar ganhos adicionais, mesmo com maior exposição a volatilidades.

A combinação das previsões dos modelos reforça que, embora o portfólio otimizado possa enfrentar desafios no curto prazo, ele se destaca como uma estratégia com maior potencial de retorno no horizonte de longo prazo, alinhada a um perfil de risco mais elevado e menos dependência dos benchmarks.

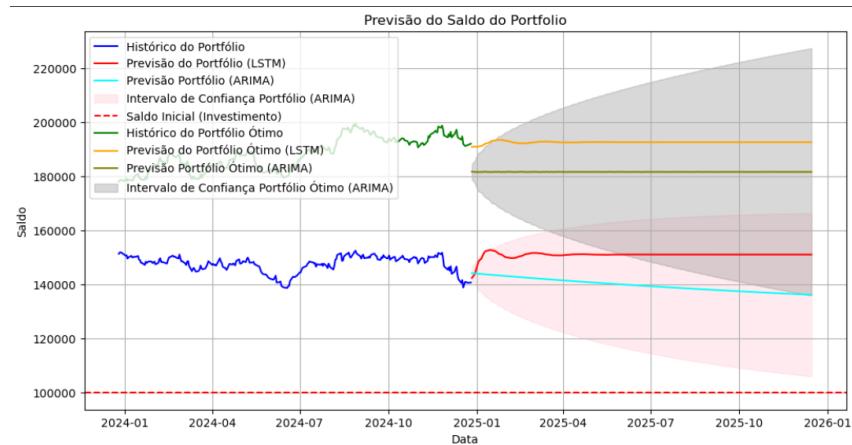


Figura 55 – Previsão detalhada do Saldo do Portfolio por LSTM e ARIMA

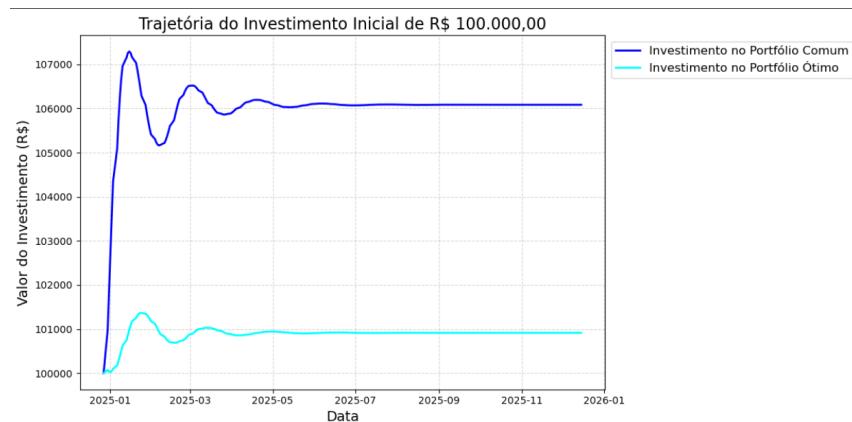


Figura 56 – Previsão do Saldo caso fosse investido nesse momento

7 Conclusão

A análise conduzida forneceu insights detalhados sobre o desempenho dos portfólios comum e otimizado em comparação com benchmarks como IBOV e CDI. O portfólio comum apresentou uma trajetória mais estável no curto prazo, com crescimento contínuo seguido de momentos de plateau, conforme indicado pelos modelos ARIMA e LSTM. Este portfólio se destacou por superar consistentemente os benchmarks, refletindo uma estratégia equilibrada de risco e retorno moderado. Por outro lado, o portfólio otimizado, embora mais volátil no curto prazo, destacou-se como a opção com maior potencial de retorno no longo prazo. A análise do CAPM reforçou essa superioridade, com um alfa significativamente mais alto, indicando a habilidade de gerar retornos acima do esperado pelo mercado.

Os comparativos revelaram que ambos os portfólios superaram benchmarks como o CDI e o IBOV em quase todos os cenários analisados. O portfólio comum manteve uma correlação mais próxima com o IBOV, enquanto o portfólio otimizado mostrou maior independência, sugerindo uma abordagem mais diferenciada e ousada. No entanto, o teste de estresse e o backtesting evidenciaram que o portfólio otimizado está mais exposto a variações extremas, como taxas de violação mais altas e maiores perdas em cenários adversos. Apesar disso, permanece a opção mais lucrativa no longo prazo.

Os modelos estatísticos e de aprendizado de máquina utilizados complementaram-se na análise. O ARIMA capturou bem as tendências passadas, enquanto o LSTM forneceu previsões úteis para dinâmicas de curto e longo prazo. Ambos os modelos reforçaram a ideia de que o portfólio otimizado, embora mais arriscado, apresenta maior potencial de retorno em horizontes estendidos.

A escolha entre os portfólios depende do perfil de risco do investidor. Para aqueles que preferem maior estabilidade e menor exposição à volatilidade, o portfólio comum é uma opção confiável. Por outro lado, investidores com maior tolerância a riscos e foco no longo prazo podem se beneficiar do portfólio otimizado, que demonstrou maior capacidade de desvincular-se de benchmarks tradicionais e gerar retornos superiores. Ambas as estratégias são robustas e superaram benchmarks relevantes, mas possuem características distintas que devem ser consideradas na alocação de capital.

8 Referências

BANCO CENTRAL DO BRASIL. *Dataset sobre IGP-M*. Disponível em:

[https://dadosabertos.bcb.gov.br/dataset?q=igpm&res_format=CSV&groups=economia-e-financas&sort\(score+desc%2C+metadata_modified+desc\)](https://dadosabertos.bcb.gov.br/dataset?q=igpm&res_format=CSV&groups=economia-e-financas&sort(score+desc%2C+metadata_modified+desc)). Acesso em: 28 dez. 2024.

KUNYOSHI, André. *Previsão de Comportamento de Ações com Machine Learning*. Medium, 2023. Disponível em: <https://andre-kuniyoshi.medium.com/previs%C3%A3o-de-comportamento-de-a%C3%A7%C3%A3o-com-machine-learning-em-19ff4fef547a>. Acesso em: 28 dez. 2024.

CORTEZ, Pedro. *Calculando o ROI de um projeto de ciência de dados: avaliando retornos financeiros*. LinkedIn Pulse, 2023. Disponível em:
<https://www.linkedin.com/pulse/calculando-o-roi-de-um-projeto-ci%C3%A3o-dados-avaliando-pedro-cortez/>. Acesso em: 28 dez. 2024.

DS ACADEMY. *10 Casos de Uso de Machine Learning em Finanças*. Blog DS Academy, 2023. Disponível em: https://blog.dsacademy.com.br/10-casos-de-uso-de-machine-learning-em_financias/. Acesso em: 28 dez. 2024.

ALVES, Matheus de Oliveira. *Projeto de Machine Learning para Decisão de Compra de uma Ação Impulsionado pela IA*. Medium, 2023. Disponível em:
<https://medium.com/@matheusdeoliveiraalves/projeto-de-machine-learning-para-decis%C3%A3o-de-compra-de-uma-a%C3%A7%C3%A3o-impulsionado-pela-ia-3c4dda08861b>. Acesso em: 28 dez. 2024.

RODELLA, Vinícius Gomes. *Estudo de Caso: Aplicação de Machine Learning para a Previsão de Tendências das Ações das Bolsas de Valores Brasileira e Norte Americana*. 2023. Disponível em: <https://repositorio.unesp.br/server/api/core/bitstreams/f17bac76-abb2-4a36-ba49-1307f3c5bd22/content>. Acesso em: 28 dez. 2024.

Bodie, Z. (2020). *Investments*. 12. ed. New York: McGraw-Hill.

Lopez de Prado, M. (2018). *Advances in Financial Machine Learning*. New York: Wiley.